

仔细观察：多模态大语言模型中用于幻觉缓解的自适应视觉增强

Xingyu Zhu^{1,2}, Kesen Zhao², Liang Yi¹, Shuo Wang¹, Zhicai Wang¹,
Beier Zhu^{2*}, Hanwang Zhang², Xiangnan He^{1*}

¹ MoE Key Lab of BIPC, University of Science and Technology of China

² Nanyang Technological University

xyzhxyz@mail.ustc.edu.cn

ABSTRACT

多模态大语言模型 (MLLMs) 在视觉-语言推理方面取得了显著进展, 但仍容易出现幻觉, 即生成内容偏离视觉证据。现有的缓解策略要么在训练过程中需要昂贵的监督, 要么在推理阶段引入额外延迟。近期的视觉增强方法试图通过在解码过程中强化视觉 token 来解决这一问题, 但通常会不加区分地注入所有 token, 导致背景区域的干扰, 使模型偏离关键线索。为克服这一挑战, 我们提出一种面向 MLLMs 的 **Adaptive vIsual Reinforcement** 框架, 简称 **AIR**。AIR 包含两个主要组件: 基于原型的 token 精简, 将大量视觉 token 压缩为一个紧凑子集以抑制冗余; 以及基于 OT 的块强化, 通过量化隐状态与块嵌入之间的对齐程度, 有选择性地整合到前馈层中。结果表明, AIR 增强了模型对显著视觉信息的依赖, 有效缓解了幻觉问题。在代表性 MLLMs 上的大量实验表明, AIR 在显著降低幻觉的同时保持了模型的通用能力, 证明其是一种高效且独立的构建可靠 MLLMs 的解决方案。

1 引言

多模态大模型 (MLLMs) (Chen et al., 2023; Zhu et al., 2024a;c; Liu et al., 2024a; Li et al., 2025; Liu et al., 2024b; Han et al., 2025; Wu et al., 2025e;a;b;d) 通过统一视觉与语言, 在交错的文本-图像输入上实现了推理, 取得了显著进展。它们已被广泛应用于任务 (Wu & Yang, 2024; Wu et al., 2025c), 例如视觉问答系统 (Wu et al., 2025a) 和图像描述 (Yang et al., 2023; Zhao et al., 2025)。尽管取得了这些进展, MLLMs 仍然容易产生幻觉 (Jiang et al., 2025; Zheng et al., 2025; Yang et al., 2025a), 即生成的内容与视觉输入不一致, 例如, 描述不存在的物体或产生矛盾的解释。这种脆弱性阻碍了其在现实场景中的部署。

现有的幻觉缓解策略大致可分为训练阶段和推理阶段的方法。训练阶段的方法 (Gunjal et al., 2024; Lyu et al., 2024; Fu et al., 2025; Yang et al., 2025b) 依赖额外的标注来微调多模态大模型 (MLLMs), 而推理阶段的方法通常采用对比解码或重排序。尽管有效, 但它们要么需要昂贵的监督信号, 要么引入额外延迟。近期的研究 (Fazli et al., 2025; Zheng & Zhang, 2025; Yin et al., 2025; Zou et al., 2024) 强化了图像 token 在解码过程中的贡献。这些方法无需标注, 且额外开销很小, 因此在实际应用中具有广泛的适用性。具体而言, 这些方法通

*Corresponding authors.

过将视觉 token 重新注入前馈网络 (FFN) (Zou et al., 2024; Yuan et al., 2025; Wan et al., 2025; Zhou et al., 2025) 来提升模型的定位能力。

尽管它们取得了成功,我们观察到视觉输入通常包含大量干扰,例如背景区域,其中可能包含冗余对象或分散语义。简单地将所有视觉 token 融合到解码过程中可能会分散模型对关键区域的注意力。如图 1(a) 所示,我们比较了两种注入策略:第一种策略,原始 token 注入 (Zou et al., 2024),会导致幻觉,因为模型会关注无关的背景区域。相比之下,通过相关 token 重新注入,模型能够有效减轻幻觉,从而聚焦于关键视觉内容。这一点也在图 1(c) 中的热力图中得到体现。为了更深入地探讨这一现象,我们在 MSCOCO 数据集上使用 LLaVA-1.5-7B 模型分析了不同解码层中隐状态与视觉 token 之间的相似度 (Lin et al., 2014)。如图 1(b) 所示,有效目标区域 (例如 patch 1 和 patch 2) 始终表现出更高的相似度,而背景区域 (patch 3) 则保持较低水平。原始图像 token 的相似度介于两者之间,表明它们稀释了显著线索的重要性。

受这些发现的启发,我们提出了 AIR,一种自适应视觉强化框架,能够增强关键证据并抑制冗余信息。与重新注入全部视觉 token 不同,AIR 基于两个核心组件构建。第一个是基于原型的 token 精简,将图像 token 压缩为一个紧凑子集,过滤掉重复的背景信号,降低计算开销。第二个是 OT 引导的区域强化,利用熵正则化的最优传输来评估隐状态与区域嵌入之间的对齐程度,确保仅有良好对齐的区域被整合到解码器的前馈网络中。这两个设计共同使模型能够聚焦于显著区域,并以无需训练且高效的方式缓解幻觉问题。

为了验证我们框架的有效性,我们在多个代表性多模态大模型 (MLLMs) 上进行了大量实验,包括 LLaVA-1.5-7B (Liu et al., 2024a)、Qwen-VL Bai et al. (2023) 和 GLM-4V-9B Zeng et al. (2024)。结果表明,AIR 在 CHAIR (Rohrbach et al., 2018) 和 POPE (Li et al., 2023b) 等基准测试中持续降低了幻觉率,同时在存在性、计数和翻译等互补任务上保持了强劲性能,如图 1(d) 所示。这些结果突显了 AIR 是一种无需训练的框架,能够在多种多模态大模型之间实现泛化,为幻觉缓解提供了一种有效解决方案。

2 相关工作

多模态大模型中的幻觉问题。当多模态大模型生成流畅但视觉上不一致的输出时,就会发生物体幻觉,这会影响多模态推理的可靠性。现有的缓解策略可分为三类。基于训练的方法通过精心构建的数据集对模型进行微调 (Gunjal et al., 2024),强制跨模态对齐 (Fu et al., 2025),或应用偏好最优化 (Yang et al., 2025b),但这些方法需要昂贵的标注和大量计算资源。后处理方法利用外部模型或轻量级修正器修改或过滤响应,例如 LURE (Zhou et al., 2024; Yin et al., 2024; Wu et al., 2024; Yang et al., 2025a; Liu et al., 2025),虽然提高了灵活性,但增加了系统复杂性。推理时干预方法在不重新训练的情况下修改解码过程,例如 Logit 挪移 (Zhao et al., 2024) 或对比解码 (Leng et al., 2024; Wang et al., 2025),具有高效性,但有时会降低稳定性。与这些范式不同,我们提出一种无需训练的方法,通过最优传输自适应校准注意力并选择性强化关键视觉区域,从而在不进行微调或使用辅助模型的情况下实现有效的幻觉抑制。

最优传输。最优传输 (OT) 通过显式建模概率质量传输的代价,提供了一种衡量分布之间差异的合理框架 (Monge, 1781)。与逐点相似度度量 (e.g., 余弦距离) 不同,OT 能够捕捉两个分布的全局几何结构,从而更准确地反映语义对齐程度。尽管精确解计算成本较高,但引入熵正则化并结合 Sinkhorn 算法 (Cuturi, 2013) 已使 OT 可扩展至高维问题。这些进展推动了广泛的应用,包括领域自适应 (Turrisi et al., 2022; Chang et al., 2022)、分布校准 (Guo et al., 2022) 以及图像识别/聚类 (Wang et al., 2023; Li et al., 2023a; Zhu et al., 2026)。在




图 1: 现有多模态大模型 (MLLMs) 幻觉缓解策略的分析。(a) 现有策略会生成不存在的物体, 而 AIR 能够产生忠实于图像的答句。(b) 解码器各层中隐状态与不同视觉 token 之间的相似度, 表明显著区域始终比无关区域具有更高的对齐度。(c) 现有重注入方法与 AIR 的注意力热力图对比: 先验方法将注意力扩散至无关区域, 而 AIR 则聚焦于语义关键区域。(d) AIR 在基准测试中有效降低幻觉, 同时对通用多模态性能影响最小。

视觉-语言建模中, OT 被用于少样本学习中对齐模态分布 (Zhou et al., 2022; Lazarou et al., 2021; Zhu et al., 2025a;b), 优化跨模态迁移的提示词 (Chen et al., 2022), 以及提升零样本泛化能力 (Zhu et al., 2024d; Fang et al., 2025; Zhu et al., 2024b; Zhou et al., 2023)。相比之下, 我们的方法在推理阶段直接使用 OT: 我们计算原始图像 token 与图像块嵌入之间的传输距离, 并将其作为细粒度准则, 以选择保留关键视觉语义的图像块。随后, 这些选中的图像块被融合进解码器, 为视觉证据提供一种轻量但分布感知的增强。

3 方法

3.1 初步研究

多模态大模型。多模态大语言模型 (MLLMs) 将传统的大型语言模型 (LLMs) 扩展为能够联合处理文本和图像的模型。一个 MLLM 通常由 视觉编码器、文本编码器 和 自回归解码器 组成。给定一个文本查询 $x = [x_1, \dots, x_L]$ 和一张图像 v , 视觉编码器提取视觉特征, 然后将其变换为对齐的视觉 token $\mathbf{Z} = [\mathbf{z}_1, \mathbf{z}_2, \dots, \mathbf{z}_K]$ 。设 $[\mathbf{x}_1, \dots, \mathbf{x}_L]$ 表示由文本编码器生成的 x 的嵌入, 定义多模态输入序列:

$$\mathbf{X} = [\mathbf{Z}, \mathbf{x}_1, \dots, \mathbf{x}_L]. \quad (1)$$

在解码步骤 t 时, 基于 Transformer 的解码器生成未经规范化的 Logit $f_\theta(\cdot | \mathbf{X}, y_{<t})$, 通过 Softmax 可获得下一个 token 的分布:

$$p_\theta(\cdot | \mathbf{X}, y_{<t}) = \text{softmax}(f_\theta(\cdot | \mathbf{X}, y_{<t})), \quad y_t \sim p_\theta(\cdot | \mathbf{X}, y_{<t}), \quad t = 1, \dots, T. \quad (2)$$

此处, θ 表示所有模型参数, $y_{<t}$ 表示先前生成的 token。




图 2: 我们提出的 AIR 框架概述。给定一个多模态输入 (图像和问题), 视觉编码器提取视觉特征, 并通过投影器将这些特征与文本嵌入对齐。在 Transformer 层内部, 视觉 token 首先通过基于原型的选择进行压缩, 以消除冗余信息, 然后利用最优传输在补丁级别进行对齐以增强表示。这些选择性增强策略丰富了隐状态中的显著视觉线索, 使 AIR 能够生成更安全、更准确且具有视觉依据的回答。

★ **最优传输**。最优传输 (OT) (Monge, 1781; Wang et al., 2023) 提供了一个量化两个概率分布之间差异的合理框架。考虑特征空间中的两个离散测度: $\mathbb{P} = \sum_{i=1}^{|V|} a_i \delta(\mathbf{v}_i - \mathbf{v})$ 和 $\mathbb{Q} = \sum_{j=1}^{|U|} b_j \delta(\mathbf{u}_j - \mathbf{u})$, 其中 δ 表示 Dirac Delta 函数, $|V|$ 和 $|U|$ 分别是 $\mathbb{P}$ 和 $\mathbb{Q}$ 中支撑点的数量。此处, $\mathbf{a} = [a_1, \dots, a_{|V|}]^\top$ 和 $\mathbf{b} = [b_1, \dots, b_{|U|}]^\top$ 是和为一的概率向量。给定一个代价矩阵 $\mathbf{C} \in \mathbb{R}^{|V| \times |U|}$, 其中 $\mathbf{C}(i, j)$ 是 $\mathbf{C}$ 中的元素, 表示将单位质量从 $\mathbf{v}_i$ 运输到 $\mathbf{u}_j$ 的代价, $\mathbb{P}$ 与 $\mathbb{Q}$ 之间的 OT 距离可表述为:

$$d_{\text{OT}}(\mathbb{P}, \mathbb{Q}; \mathbf{C}) = \min_{\mathbf{T}} \langle \mathbf{T}, \mathbf{C} \rangle, \quad \text{s.t. } \mathbf{T} \mathbf{1}_{|U|} = \mathbf{a}, \quad \mathbf{T}^\top \mathbf{1}_{|V|} = \mathbf{b}, \quad (3)$$

其中 $\mathbf{T} \in \mathbb{R}^{|V| \times |U|}$ 表示传输计划, 指定了质量在两个分布之间如何移动。符号 $\langle \cdot, \cdot \rangle$ 表示 Frobenius 内积, $\mathbf{1}_{|V|}$ 是维度为 $|V|$ 的全 1 向量。直接求解公式 (3) 计算复杂度较高。先验工作 (Lazarou et al., 2021; Chen et al., 2022) 通过采用 Sinkhorn 算法 (Cuturi, 2013) 来解决此问题, 该算法引入熵正则化以实现高效的最优化:

$$d_{\text{OT}}(\mathbb{P}, \mathbb{Q}; \mathbf{C}) = \min_{\mathbf{T}} \langle \mathbf{T}, \mathbf{C} \rangle - \epsilon h(\mathbf{T}), \quad (4)$$

其中 $h(\cdot)$ 表示熵, $\epsilon \geq 0$ 控制正则化的强度。

3.2 自适应视觉强化

基于原型的 token 压缩。我们的视觉增强策略在每个 Transformer 块的前馈网络 (FFN) 中运行, 该网络由两个全连接层和一个非线性激活值组成:

$$\text{FFN}(\mathbf{H}) = \phi(\mathbf{H} \mathbf{W}_1) \mathbf{W}_2^\top, \quad (5)$$

其中 $\phi(\cdot)$ 表示激活函数, $\mathbf{H}$ 表示隐状态。随着 Transformer 层级加深, 注意力逐渐趋向于文本 token, 这导致视觉 token 在后续层中的贡献度降低。一种常见的解决方案是将视觉 token 重新注入到 FFN (Zou et al., 2024) 中:

$$\text{FFN}(\mathbf{H}|\mathbf{Z}) = \phi(\mathbf{H} \mathbf{Z}^\top) \mathbf{Z}, \quad (6)$$

其中 $\mathbf{Z}$ 表示通过投影器对齐的视觉 token。然而, 由于视觉 token 是从整个图像中提取的, 其长度 K 通常较大 (例如 LLaVA 中的 $K = 576$), 这会引入冗余和噪声。直接重新注入所有 token 不仅会产生不必要的计算开销, 还会使模型无法专注于最具信息量的区域。为了解决这个问题, 我们首先将 $\mathbf{H}$ 精简为一个紧凑的子集。我们计算一个原型 $\mathbf{h}_p = \frac{1}{K} \sum_{k=1}^K \mathbf{h}_k$ 作为视觉语义的粗略总结, 并根据 token 到该原型的距离对其进行排序:

$$d(\mathbf{h}_k, \mathbf{h}_p) = \|\mathbf{h}_k - \mathbf{h}_p\|_2, \quad k = 1, \dots, K. \quad (7)$$

距离较大的 token 编码了全局原型未捕捉到的更显著特征。因此，我们仅保留 Top Q 个 token：

$$\mathbf{H}' \leftarrow \{\mathbf{h}_k \mid k \in \text{Top}_Q(\{d(\mathbf{h}_k, \mathbf{h}_p)\})\}, \quad (8)$$

确保后续的强化作用于一组紧凑的视觉表示。

基于 OT 的补丁增强。 尽管原型选择能够减少全局冗余，但不同的图像区域在重要性上仍可能存在差异。为了进一步突出关键细节，我们将图像裁剪为多个图像块 $\{\hat{v}^m\}_{m=1}^M$ ，并获取对应的嵌入 $\{\hat{\mathbf{Z}}^m\}_{m=1}^M$ ，其中每个 $\hat{\mathbf{Z}}^m = [\mathbf{z}_1^m, \mathbf{z}_2^m, \dots, \mathbf{z}_N^m]$ 编码了细粒度的视觉细节。我们将原始隐状态和块级 token 建模为离散分布：

$$\mathbb{P}(\mathbf{h}) = \sum_{k=1}^Q a_k \delta(\mathbf{h}_k - \mathbf{h}), \quad \mathbb{Q}_m(\hat{\mathbf{z}}) = \sum_{n=1}^N b_n^m \delta(\hat{\mathbf{z}}_n^m - \hat{\mathbf{z}}), \quad (9)$$

其中 $\delta(\cdot)$ 表示 Dirac Delta 函数， a_k 、 b_n^m 为规范化的重要性权重。使用 OT 距离量化 $\mathbb{P}$ 与 $\mathbb{Q}_m$ 之间的对齐程度：

$$d_{\text{OT}}(\mathbb{P}, \mathbb{Q}_m; \mathbf{C}_m) = \min_{\mathbf{T}_m \geq 0} \langle \mathbf{T}_m, \mathbf{C}_m \rangle, \quad \text{s.t.} \quad \mathbf{T}_m \mathbf{1}_Q = \mathbf{a}, \quad \mathbf{T}_m^\top \mathbf{1}_N = \mathbf{b}_m, \quad (10)$$

其中 $\mathbf{a} = [\frac{1}{Q}, \dots, \frac{1}{Q}]^\top$ ， $\mathbf{b}_m = [\frac{1}{N}, \dots, \frac{1}{N}]^\top$ ，以及 $\mathbf{C}_m(k, n) = 1 - \cos(\mathbf{z}_k, \hat{\mathbf{z}}_n^m)$ 。通过 Sinkhorn-Knopp 算法 (Zhu et al., 2024d; Chen et al., 2022) 可高效地获得传输计划 $\mathbf{T}_m$ 。对于每个块 m ，我们计算一个聚合的 OT 距离：

$$d_{\text{OT}}(m) = \sum_{k=1}^Q \sum_{n=1}^N \mathbf{T}_m(k, n) \mathbf{C}_m(k, n). \quad (11)$$

较低的 OT 距离表明与原始图像的对齐程度更强，因此说明该补丁保留了更多的关键视觉信息。因此，我们选择满足阈值条件的补丁 τ ：

$$\mathcal{M} = \{m \mid d_{\text{OT}}(m) \leq \tau\}. \quad (12)$$

这些选定的图像块的嵌入随后与原始图像 token 融合：

$$\tilde{\mathbf{Z}} \leftarrow \text{concat}(\{\hat{\mathbf{Z}}^m \mid m \in \mathcal{M}\}). \quad (13)$$

这种选择性融合增强了表示中关键的视觉细节，强化了图像信息在隐状态中的作用。最终重新注入前馈网络 (FFN) 的表达式为：

$$\text{FFN}(\mathbf{H}|\tilde{\mathbf{Z}}) = \phi(\mathbf{H} \mathbf{W}_1) \mathbf{W}_2^\top + \phi(\mathbf{H}' \tilde{\mathbf{Z}}^\top) \tilde{\mathbf{Z}} \quad (14)$$

3.3 理论分析

为了验证我们基于 OT 的补丁选择在动态令牌注入中的有效性，我们对比了我们的 OT 距离度量 $d_{\text{OT}}(m)$ 与基准余弦距离 $d_{\text{cos}}(m) = \frac{1}{KN} \sum_{k=1}^K \sum_{n=1}^N \mathbf{C}_m(k, n)$ 的敏感性。在我们的框架中，若 $d_{\text{OT}}(m) \leq \tau$ ，则补丁 m 被选为有用，因为较低的 OT 距离表明与关键视觉语义具有更强的一致性。相反，对于余弦基准，若 $d_{\text{cos}}(m) \leq \tau_{\text{cos}}$ ，则补丁被选中，这反映了不一致。我们证明了基于 OT 的方法在区分补丁方面具有严格更高的敏感性：

$$|d_{\text{OT}}(m_1) - d_{\text{OT}}(m_2)| > |d_{\text{cos}}(m_1) - d_{\text{cos}}(m_2)|, \quad (15)$$

除了在退化情形下，其中 $\mathbf{C}_{m_1} = \mathbf{C}_{m_2}$ 。

表 1: 不同方法在 MSCOCO 数据集上对多模态大模型 (MLLMs) 的 CHAIR 评估结果。本实验中最大 token 数设为 64。加粗表示所有方法中的最佳结果。

Method	LLaVA-1.5-7B			Qwen-VL-Chat			GLM-4V-9B		
	CHAIR _S ↓	CHAIR _I ↓	BLEU ↑	CHAIR _S ↓	CHAIR _I ↓	BLEU ↑	CHAIR _S ↓	CHAIR _I ↓	BLEU ↑
Vanilla	22.0 ↑0.0	6.7 ↑0.0	14.5 ↑0.0	20.0 ↑0.0	6.2 ↑0.0	13.5 ↑0.0	13.0 ↑0.0	5.6 ↑0.0	9.8 ↑0.0
VCD	24.6 ↑2.6	7.3 ↑0.6	13.9 ↓0.6	19.2 ↓0.8	5.7 ↓0.5	13.4 ↑0.1	14.8 ↑1.8	6.5 ↑0.9	9.5 ↓0.3
MemVR	21.6 ↓0.4	6.4 ↓0.3	14.4 ↓0.1	20.0 ↑0.0	6.1 ↓0.1	13.3 ↓0.2	13.0 ↑0.0	5.6 ↑0.0	9.8 ↑0.0
VAF	20.4 ↓1.6	6.5 ↓0.2	14.6 ↑0.1	20.6 ↑0.6	6.6 ↑0.4	13.4 ↓0.1	11.6 ↓1.4	5.3 ↓0.3	9.7 ↓0.1
AIR	18.4 ↓3.6	5.7 ↓1.0	14.4 ↓0.1	18.6 ↓1.4	5.9 ↓0.3	13.6 ↑0.1	11.6 ↓1.4	5.3 ↓0.3	9.7 ↓0.1

为什么 OT 能增强补丁选择的灵敏度。 基于 OT 的度量采用通过 Sinkhorn-Knopp 计算的自适应传输方案 $\mathbf{T}_m$, 优先考虑原始 token 与块 token 之间低代价对齐 (高余弦相似性)。这种自适应加权增强了语义对齐的差异, 使得分离度 $|d_{\text{OT}}(m_1) - d_{\text{OT}}(m_2)|$ 比 d_{cos} 的均匀加权更大, 后者对所有成对代价取平均, 削弱了区分性特征。更高的敏感性确保了在 $\mathcal{M}$ 中更精确地识别出捕捉关键视觉信息的块。证明见附录 C。

4 实验

在本节中, 我们展示了我们的方法在幻觉和通用基准上的实验结果, 包括性能对比、消融研究和可视化分析。

4.1 实验设置

基础模型与基准方法。 我们在三个多模态大模型上验证了我们的方法, 包括 LLaVA-1.5-7B (Liu et al., 2024a)、Qwen-VL-Chat (Bai et al., 2023) 和 GLM-4V-9B (Zeng et al., 2024)。为进行对比, 我们引入了几种前沿的物体幻觉缓解方法: VCD (Leng et al., 2024)、MemVR (Zou et al., 2024) 和 VAF (Yin et al., 2025)。

评估基准与指标。 我们在多种基准上评估了我们的方法。对于幻觉评估, 我们在 500 个随机采样的 MSCOCO (Lin et al., 2014) 图像上使用 CHAIR (Rohrbach et al., 2018), 以及在 MSCOCO、A-OKVQA (Schwenk et al., 2022) 和 GQA (Hudson & Manning, 2019) 上使用 POPE (Li et al., 2023b)。对于通用评估, 我们采用 LLaVA-Bench (Liu et al., 2023)、MME (Fu et al., 2023) 和 MMBench (Liu et al., 2024c)。作为评估指标, 我们报告 CHAIR_S、CHAIR_I、BLEU、准确率和 F1 得分。详细的描述与实现方法见附录 B.1 和 B.2。

4.2 幻觉基准测试表现

如表 1 所示, AIR 在三种代表性 MLLMs 上始终取得最低的 CHAIR_S 和 CHAIR_I, 表明其在抑制幻觉方面的有效性。例如, 在 LLaVA-1.5-7B 上, AIR 将 CHAIR_S 从 22.0 降至 18.4, 将 CHAIR_I 从 6.7 降至 5.7, 同时保持了相近的 BLEU 得分。这证实了选择性地强化显著 token 比盲目重注入更能可靠地缓解幻觉。表 2 进一步验证了 AIR 在 POPE 基准上的鲁棒性。在 MSCOCO、A-OKVQA 和 GQA 上, AIR 在随机、常见和对抗情景下均取得了最佳或接近最佳的准确率和 F1 得分。值得注意的是, 即使在对抗性提示下, AIR 仍保持优异表现, 优于 MemVR 等先前的防御方法。更多实验结果见附录 B.3, 表 8 和 9。

表 2: 在使用 LLaVA-1.5-7B 进行的 POPE 基准测试中的性能表现。加粗数字表示最佳结果。我们报告了三种情景下的准确率和 F1 得分，即 *Random*、*Popular* 和 *Adversarial*，以展示不同方法的鲁棒性。

Datasets	Methods	Random		Popular		Adversarial	
		Accuracy ↑	F1-score ↑	Accuracy ↑	F1-score ↑	Accuracy ↑	F1-score ↑
MSCOCO	Vanilla	83.7 ↑0.0	83.0 ↑0.0	78.2 ↑0.0	78.4 ↑0.0	75.0 ↑0.0	76.0 ↑0.0
	VCD	85.4 ↑1.7	83.7 ↑0.7	84.3 ↑6.1	83.0 ↑4.6	81.8 ↑6.8	80.9 ↑4.9
	MemVR	87.6 ↑3.9	86.2 ↑3.2	86.0 ↑7.8	84.7 ↑6.3	83.5 ↑8.5	82.5 ↑6.5
	VAF	87.6 ↑3.9	86.2 ↑3.2	86.2 ↑8.0	85.0 ↑6.6	83.9 ↑8.9	82.8 ↑6.8
	AIR	89.0 ↑5.3	88.2 ↑5.2	87.1 ↑8.9	86.4 ↑8.0	83.9 ↑8.9	83.6 ↑7.6
A-OKVQA	Vanilla	83.4 ↑0.0	82.6 ↑0.0	79.9 ↑0.0	79.6 ↑0.0	74.0 ↑0.0	75.1 ↑0.0
	VCD	85.9 ↑2.5	85.4 ↑2.8	81.9 ↑2.0	82.0 ↑2.4	76.7 ↑2.7	78.4 ↑3.3
	MemVR	89.0 ↑5.6	88.5 ↑5.9	84.6 ↑4.8	84.6 ↑5.1	78.3 ↑4.3	79.6 ↑4.5
	VAF	88.7 ↑5.3	88.3 ↑5.7	84.1 ↑4.2	84.3 ↑4.7	76.9 ↑2.9	78.7 ↑3.6
	AIR	89.2 ↑5.8	88.9 ↑6.3	84.4 ↑4.5	84.7 ↑5.1	78.0 ↑4.0	79.7 ↑4.6
GQA	Vanilla	83.7 ↑0.0	83.0 ↑0.0	78.2 ↑0.0	78.4 ↑0.0	75.1 ↑0.0	76.1 ↑0.0
	VCD	86.3 ↑2.6	85.8 ↑2.8	78.4 ↑0.2	79.0 ↑0.6	76.2 ↑1.1	77.4 ↑1.3
	MemVR	89.3 ↑5.6	88.9 ↑5.9	82.9 ↑4.7	83.4 ↑5.0	80.3 ↑5.2	81.4 ↑5.3
	VAF	88.1 ↑4.4	87.7 ↑4.7	79.4 ↑1.2	80.6 ↑2.2	78.2 ↑3.1	79.7 ↑3.6
	AIR	89.7 ↑6.0	89.5 ↑6.5	83.0 ↑4.8	83.8 ↑5.4	80.4 ↑5.3	81.7 ↑5.6

表 3: MME 幻觉子集与 MMBench 的评估结果对比。

	Methods	MME-Hall	Object-Level		Attribute-Level		Cognition	MMBench
		Total ↑	Existence ↑	Count ↑	Position ↑	Color ↑	Score ↑	Accuracy ↑
LLaVA-1.5	Vanilla	643.3 ↑0.0	190.0 ↑0.0	155.0 ↑0.0	128.3 ↑0.0	170.0 ↑0.0	357.8 ↑0.0	64.6 ↑0.0
	VCD	613.3 ↓30.	190.0 ↑0.0	140.0 ↓15.	118.3 ↓10.	165.0 ↓5.0	337.1 ↓20.	61.6 ↓3.0
	MemVR	648.3 ↑5.0	190.0 ↑0.0	155.0 ↑0.0	133.3 ↑5.0	170.0 ↑0.0	378.6 ↑20.	64.6 ↑0.0
	VAF	603.3 ↓40.	190.0 ↑0.0	135.0 ↓20.	108.3 ↓20.	170.0 ↑0.0	322.8 ↓35.	14.8 ↓49.
	AIR	638.3 ↓5.0	190.0 ↑0.0	155.0 ↑0.0	123.3 ↓5.0	170.0 ↑0.0	372.5 ↑14.	64.7 ↑0.1
Qwen-VL	Vanilla	631.7 ↑0.0	185.0 ↑0.0	145.0 ↑0.0	126.7 ↑0.0	175.0 ↑0.0	342.8 ↑0.0	59.9 ↑0.0
	VCD	626.7 ↓5.0	180.0 ↓5.0	145.0 ↑0.0	126.7 ↑0.0	175.0 ↑0.0	348.9 ↑6.1	60.3 ↑0.4
	MemVR	636.7 ↑5.0	185.0 ↑0.0	145.0 ↑0.0	131.7 ↑5.0	175.0 ↑0.0	337.5 ↓5.3	60.0 ↑0.1
	VAF	631.7 ↑0.0	185.0 ↑0.0	145.0 ↑0.0	126.7 ↑0.0	175.0 ↑0.0	329.3 ↓14.	60.0 ↑0.1
	AIR	636.7 ↑5.0	185.0 ↑0.0	145.0 ↑0.0	126.7 ↑0.0	180.0 ↑5.0	352.1 ↑9.3	60.0 ↑0.1
GLM-4V-9B	Vanilla	703.3 ↑0.0	200.0 ↑0.0	168.3 ↑0.0	156.7 ↑0.0	178.3 ↑0.0	479.6 ↑0.0	81.3 ↑0.0
	VCD	696.7 ↓6.6	200.0 ↑0.0	170.0 ↑1.7	151.7 ↓5.0	175.0 ↓3.3	485.0 ↑5.4	80.2 ↓1.1
	MemVR	703.3 ↑0.0	200.0 ↑0.0	168.3 ↑0.0	156.7 ↑0.0	178.3 ↑0.0	479.6 ↑0.0	81.3 ↑0.1
	VAF	703.3 ↑0.0	200.0 ↑0.0	173.3 ↑5.0	151.7 ↓5.0	178.3 ↑0.0	479.6 ↑0.0	81.3 ↓5.7
	AIR	703.3 ↑0.0	200.0 ↑0.0	173.3 ↑5.0	151.7 ↓5.0	178.3 ↑0.0	479.6 ↑0.0	81.3 ↑0.1

4.3 通用基准上的性能

如表 3 所示，AIR 在 MME 和 MMBench 上保持了强劲的性能，在对象级和属性级任务上均取得了与现有方法相当或更优的结果。这表明选择性增强并未损害模型的通用推理能力。

表 4: GPT-4V 辅助评估在 LLaVA-Bench 上的结果，遵循 (Leng et al., 2024) 中的情景。两种指标均采用 10 分制。

Model	Method	Accuracy $\uparrow$	Detailedness $\uparrow$
LLaVA-1.5	Vanilla	5.59	4.72
	AIR	5.83	5.12
Qwen-VL-Chat	Vanilla	5.85	4.98
	AIR	6.18	5.12
GLM-4V-9B	Vanilla	6.76	5.32
	AIR	6.93	5.52

表 5: 我们的方法在不同解码层值域下，LLaVA-1.5-7B 的性能对比。

$\{\ell\}$	CHAIR $_S$ $\downarrow$	CHAIR $_I$ $\downarrow$	BLEU $\uparrow$
16-32	19.6	6.0	14.5
18-32	19.2	6.0	14.4
20-32	19.0	5.5	14.4
22-32	19.4	5.8	14.5
24-32	18.8	6.0	14.4
26-32	18.4	5.7	14.4
28-32	19.4	5.7	14.5
30-32	22.0	6.7	14.5

表 6: 在使用 LLaVA-1.5-7B 对 CHAIR 进行的消融实验中，我们消融了两个对齐组件：基于原型的 token 压缩和基于 OT 的 patch 增强。

Model	Prototype-based	OT-based	CHAIR	
	Token Reduction	Patch Reinforcement	CHAIR $_S$ $\downarrow$	CHAIR $_I$ $\downarrow$
LLaVA-1.5-7B	$\times$	$\times$	22.7	6.7
	$\times$	$\checkmark$	22.3	6.5
	$\checkmark$	$\times$	20.2	6.2
	$\checkmark$	$\checkmark$	19.8	5.8

表 4 进一步显示，AIR 在 LLaVA-Bench 的 GPT-4V 辅助评估中持续提升表现。在所有模型中，准确率 (Accuracy) 和细节度 (Detailedness) 得分均有所提高，证实了 AIR 在保持广泛多模态能力的同时提升了输出质量。MME 和 MMBench 的详细结果见附录 B.3，表 10 和 11。

4.4 消融研究

操作层的影响。为评估操作层的选择对性能的影响，我们在 CHAIR 数据集上对 LLaVA-1.5-7B 进行了消融实验，结果如表 5 所示。参照先前工作 (Zou et al., 2024; Yin et al., 2025; Yang et al., 2025a) 强调中深层在视觉-语言融合中的作用，我们从第 16 层开始分析。结果表明，在范围 24–32 增强视觉 token 能获得最有利的权衡，使 CHAIR $_S$ (18.8) 最低，同时保持 CHAIR $_I$ (6.0) 和 BLEU (14.4) 稳定。相比之下，过晚应用增强（如 30–32）或在过宽的跨度上进行（如 18–32）会导致更高的幻觉得分，表明非常深层的层过于文本有偏，而过宽的范围会稀释效果。这些发现证实，中深层是增强视觉定位且保持生成质量的最佳操作区域。

不同组件的有效性。表 6 展示了在 CHAIR 上的消融实验结果。同时移除两个组件时，幻觉率最高，突显了视觉强化的重要性。仅采用基于原型的 token 减少可使 CHAIR $_S$ 从 22.7 降至 22.3，表明压缩冗余 token 能带来适度提升。仅使用 OT-based patch 强化可实现更大的改进（从 22.7 降至 20.2），证实了分布感知 patch 选择的有效性。当两个模块联合使用时，CHAIR $_S$ 进一步降低至 19.8，CHAIR $_I$ 下降至 5.8，表明这两个组件具有互补性，并共同有助于缓解幻觉问题。




图 3: 不同保留视觉 token 数量下的性能 Top_Q .




图 4: 不同基于 OT 的距离阈值 τ 下的性能






图 5: 随着选择的图像块数量增加, 性能表现。



(a) OT 与余弦距离的边际差异分布。



(b) OT 与余弦距离的边界比较。



(c) 原始图像和 OT 选择的图像块示例。

图 6: 基于 OT 的补丁选择与基于余弦的补丁选择的对比分析。(a) OT 产生的边际差异始终大于余弦。(b) 大多数补丁级别的结果位于 $y = x$ 线之上, 表明 OT 在补丁之间提供了更清晰的分离。(c) 定性证据显示, OT 聚焦于与原图对齐的视觉信息丰富的区域。

Top_Q 选择的影响。如图 3 所示, 增加保留的视觉 token 数量 Top_Q 会持续减少幻觉现象, 这体现在 CHAIR_s 的下降上。该结果表明, 基于原型的选择方法能成功保留最具判别性的线索, 同时滤除冗余信息。此外, BLEU 得分基本保持不变, 说明语义保真度得以维持, 且未损害语言生成质量。

阈值 τ 的影响。图 4 显示, 改变 OT 阈值 τ 会呈现出一种 U 型性能趋势。阈值过严会移除有信息量的区域, 削弱视觉定位能力并增加幻觉现象; 而阈值过松则会引入无关区域和噪声。适中的 τ 值在选择性和覆盖之间取得了最佳平衡, 从而降低了 CHAIR_s 并保持了稳定的 BLEU 值, 证实了基于 OT 的区域选择的有效性。

增强补丁的影响。图 5 量化了扩大基于 OT 选择的补丁池的影响: 候选补丁越多, 运输方案就能匹配成本更低、对齐更好的区域, 从而产生更强的视觉证据。相应地, CHAIR_s 稳定下降, 而 BLEU 基本保持不变, 表明增加候选覆盖范围在不损害流畅性的情况下提升了所选视觉信息的质量。

4.5 基于 OT 的补丁增强分析

我们使用 LLaVA 作为主干模型, 在 CHAIR 基准上评估基于 OT 的补丁强化。图 6 提供了定量和定性证据, 表明其优于基于余弦的选择方法。在 (a) 中, 边际差异的分布显示, OT 一致地在安全补丁与不安全补丁之间产生更大的差距, 证实了其更强的区分能力。图 (b) 中的散点图进一步支持这一观察结果, 因为大多数点位于 $y = x$ 线之上, 表明 OT 在补丁级比较中实现了更显著的分离。重要的是, (c) 中来自 LLaVA-Bench 的定性示例进一步说明, 由 OT 选择的补丁集中在与图像语义对齐的视觉显著区域。综上所述, 这些结果验证了 OT 中自适应运输计划能够突出有意义的线索并减少冗余, 从而提升模型缓解幻觉的能力。

表 7: 在使用单块 A100 GPU 的情况下, 对 CHAIR 的推理速度、GPU 内存占用和幻觉表现进行比较。

Model	Avg. Latency ↓	GPU Memory ↓	CHAIR _s ↓	CHAIR _i ↓
LLaVA-1.5-7B	1.68s	13.5G	22.0	6.7
VAF	1.69s	13.5G	20.4	6.5
MemVR	2.05s	13.6G	21.6	6.4
AIR	2.07s	13.7G	18.4	5.7

4.6 效率对比

表 7 中的对比表明, 我们的方法在保持效率的同时显著提升了安全性。LLaVA-1.5-7B 的幻觉率最高 (CHAIR_s = 22.0, CHAIR_i = 6.7)。VAF 和 MemVR 实现了中等程度的降低, 将 CHAIR_s 降至 20.4 和 21.6, 将 CHAIR_i 降至 6.5 和 6.4, 但相对于基准方法的改进有限。相比之下, 我们的框架实现了最低的幻觉率 (CHAIR_s = 18.4, CHAIR_i = 5.7), 在句子级别和物体级别准确率上均表现出明显提升。这些安全性的提升伴随着轻微的延迟增加 (2.07 秒 vs. LLaVA 的 1.68 秒) 和 GPU 内存占用增加 (13.7G vs. 13.5G), 但与所获得的鲁棒性收益相比, 开销仍处于可接受范围。总体而言, 结果证明了我们的方法在抑制幻觉的同时保持高效性的有效性。

5 局限性 & 未来讨论

尽管 AIR 在缓解幻觉方面表现出明显效果, 但其在推理型多模态模型和智能体中的应用尚未得到探索。未来工作可将 AIR 扩展至更广泛的情景, 在这些情景中, 自适应强化可能进一步提升复杂推理任务下的鲁棒性。此外, OT 在捕捉分布差异方面的优势表明其在多模态对齐问题中具有更广泛的应用潜力。将基于 OT 的强化应用于跨模态定位与对齐, 仍是未来研究的一个有前景方向。

6 结论

在本工作中, 我们提出了 AIR (自适应视觉强化框架), 用于缓解多模态大模型中的幻觉问题。AIR 结合基于原型的 token 缩减与基于最优传输 (OT) 的图像块强化, 能够有选择性地增强显著的视觉线索, 同时抑制冗余信息。在代表性多模态大模型 (包括 LLaVA-1.5-7B、Qwen-VL 和 GLM-4V-9B) 上的实验表明, AIR 在显著降低幻觉的同时, 仍能保持强大的多模态性能。总体而言, AIR 为构建可靠的多模态大模型提供了一种无需训练且高效可行的解决方案。

伦理声明

我们的方法通过引导大模型关注关键视觉区域并抑制背景干扰，减少了多模态大模型中的幻觉现象。这提升了模型对视觉证据的定位能力，增强了生成结果的可靠性。然而，由于多模态大模型是在大规模网络数据上训练的，仍存在继承偏见和有害内容等风险。因此，我们建议在实际应用中负责任地使用，并进行持续监控。

可复现性声明

我们已采取多项措施以确保可复现性。数据集、数据处理及推理流程的详细描述见主论文(第 3 和 4 节)以及附录 B。这些资料使其他研究人员能够可靠地复现我们的结果，并在此基础上进一步开展工作。

致谢

本研究得到国家自然科学基金 (U24B20180, 编号: 62576330) 和安徽省自然科学基金 (编号: 2508085MF143) 的资助。

参考文献

- Jinze Bai, Shuai Bai, Shusheng Yang, Shijie Wang, Sinan Tan, Peng Wang, Junyang Lin, Chang Zhou, and Jingren Zhou. Qwen-vl: A versatile vision-language model for understanding, localization, text reading, and beyond. *arXiv preprint arXiv:2308.12966*, 2023.
- Wanxing Chang, Ye Shi, Hoang Tuan, and Jingya Wang. Unified optimal transport framework for universal domain adaptation. In *NeurIPS*, 2022.
- Guangyi Chen, Weiran Yao, Xiangchen Song, Xinyue Li, Yongming Rao, and Kun Zhang. Plot: Prompt learning with optimal transport for vision-language models. 2022.
- Zhe Chen, Jiannan Wu, Wenhai Wang, Weijie Su, Guo Chen, Sen Xing, Muyan Zhong, Qinglong Zhang, Xizhou Zhu, Lewei Lu, Bin Li, Ping Luo, Tong Lu, Yu Qiao, and Jifeng Dai. Internvl: Scaling up vision foundation models and aligning for generic visual-linguistic tasks. *CoRR*, abs/2312.14238, 2023.
- Marco Cuturi. Sinkhorn distances: Lightspeed computation of optimal transport. In *NeurIPS*, 2013.
- Xiang Fang, Wanlong Fang, and Changshuo Wang. Hierarchical semantic-augmented navigation: Optimal transport and graph-driven reasoning for vision-language navigation. In *Advances in Neural Information Processing Systems*, 2025.
- Mehrdad Fazli, Bowen Wei, and Ziwei Zhu. Mitigating hallucination in large vision-language models via adaptive attention calibration. *CoRR*, abs/2505.21472, 2025.
- Chaoyou Fu, Peixian Chen, Yunhang Shen, Yulei Qin, Mengdan Zhang, Xu Lin, Zhenyu Qiu, Wei Lin, Jinrui Yang, Xiawu Zheng, Ke Li, Xing Sun, and Rongrong Ji. MME: A comprehensive evaluation benchmark for multimodal large language models. *CoRR*, abs/2306.13394, 2023.

-
- Jinlan Fu, Shenzhen Huangfu, Hao Fei, Xiaoyu Shen, Bryan Hooi, Xipeng Qiu, and See-Kiong Ng. Chip: Cross-modal hierarchical direct preference optimization for multimodal llms. In *ICLR*, 2025.
- Anisha Gunjal, Jihan Yin, and Erhan Bas. Detecting and preventing hallucinations in large vision language models. In *AAAI*, 2024.
- Dandan Guo, Long Tian, He Zhao, Mingyuan Zhou, and Hongyuan Zha. Adaptive distribution calibration for few-shot learning with hierarchical optimal transport. In *NeurIPS*, 2022.
- Zhiyuan Han, Beier Zhu, Yanlong Xu, Peipei Song, and Xun Yang. Benchmarking and bridging emotion conflicts for multimodal emotion reasoning. In *ACM MM*, 2025.
- Drew A. Hudson and Christopher D. Manning. GQA: A new dataset for real-world visual reasoning and compositional question answering. In *CVPR*, 2019.
- Zhangqi Jiang, Junkai Chen, Beier Zhu, Tingjin Luo, Yankun Shen, and Xu Yang. Devils in middle layers of large vision-language models: Interpreting, detecting and mitigating object hallucinations via attention lens. In *CVPR*, 2025.
- Michalis Lazarou, Tania Stathaki, and Yannis Avrithis. Iterative label cleaning for transductive and semi-supervised few-shot learning. In *ICCV*, 2021.
- Sicong Leng, Hang Zhang, Guanzheng Chen, Xin Li, Shijian Lu, Chunyan Miao, and Lidong Bing. Mitigating object hallucinations in large vision-language models through visual contrastive decoding. In *CVPR*, 2024.
- Bo Li, Yuanhan Zhang, Dong Guo, Renrui Zhang, Feng Li, Hao Zhang, Kaichen Zhang, Peiyuan Zhang, Yanwei Li, Ziwei Liu, and Chunyuan Li. Llava-onevision: Easy visual task transfer. *Trans. Mach. Learn. Res.*, 2025, 2025.
- Miaoge Li, Dongsheng Wang, Xinyang Liu, Zequn Zeng, Ruiying Lu, Bo Chen, and Mingyuan Zhou. Patchct: Aligning patch set and label set with conditional transport for multi-label image classification. In *ICCV*, 2023a.
- Yifan Li, Yifan Du, Kun Zhou, Jinpeng Wang, Wayne Xin Zhao, and Ji-Rong Wen. Evaluating object hallucination in large vision-language models. In *EMNLP*, 2023b.
- Tsung-Yi Lin, Michael Maire, Serge J. Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C. Lawrence Zitnick. Microsoft COCO: common objects in context. In *ECCV (5)*, 2014.
- Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. In *NeurIPS*, 2023.
- Haotian Liu, Chunyuan Li, Yuheng Li, and Yong Jae Lee. Improved baselines with visual instruction tuning. In *CVPR*, 2024a.
- Haotian Liu, Chunyuan Li, Yuheng Li, Bo Li, Yuanhan Zhang, Sheng Shen, and Yong Jae Lee. Llava-next: Improved reasoning, ocr, and world knowledge, 2024b. URL <https://llava-vl.github.io/blog/2024-01-30-llava-next/>.

-
- Sheng Liu, Haotian Ye, and James Zou. Reducing hallucinations in large vision-language models via latent space steering. In *ICLR*, 2025.
- Yuan Liu, Haodong Duan, Yuanhan Zhang, Bo Li, Songyang Zhang, Wangbo Zhao, Yike Yuan, Jiaqi Wang, Conghui He, Ziwei Liu, Kai Chen, and Dahua Lin. Mmbench: Is your multi-modal model an all-around player? In *ECCV (6)*, 2024c.
- Xinyu Lyu, Beita Chen, Lianli Gao, Hengtao Shen, and Jingkuan Song. Alleviating hallucinations in large vision-language models through hallucination-induced optimization. In *NeurIPS*, 2024.
- Gaspard Monge. Mémoire sur la théorie des déblais et des remblais. *Mem. Math. Phys. Acad. Royale Sci.*, pp. 666–704, 1781.
- Shangpin Peng, Senqiao Yang, Li Jiang, and Zhuotao Tian. Mitigating object hallucinations via sentence-level early intervention. In *ICCV*, 2025.
- Anna Rohrbach, Lisa Anne Hendricks, Kaylee Burns, Trevor Darrell, and Kate Saenko. Object hallucination in image captioning. In *EMNLP*, 2018.
- Dustin Schwenk, Apoorv Khandelwal, Christopher Clark, Kenneth Marino, and Roozbeh Mottaghi. A-OKVQA: A benchmark for visual question answering using world knowledge. In *ECCV (8)*, 2022.
- Rosanna Turrisi, Rémi Flamary, Alain Rakotomamonjy, and Massimiliano Pontil. Multi-source domain adaptation via weighted joint distributions optimal transport. In *UAI*, 2022.
- Zifu Wan, Ce Zhang, Silong Yong, Martin Q. Ma, Simon Stepputtis, Louis-Philippe Morency, Deva Ramanan, Katia P. Sycara, and Yaqi Xie. ONLY: one-layer intervention sufficiently mitigates hallucinations in large vision-language models. *CoRR*, abs/2507.00898, 2025.
- Chao Wang, Xuancheng Zhou, Weiwei Fu, and Yang Zhou. Mitigating hallucinations in large vision-language models with internal fact-based contrastive decoding. *CoRR*, abs/2502.01056, 2025.
- Dongsheng Wang, Miaoge Li, Xinyang Liu, MingSheng Xu, Bo Chen, and Hanwang Zhang. Tuning multi-mode token-level prompt alignment across modalities. 2023.
- Junfei Wu, Qiang Liu, Ding Wang, Jinghao Zhang, Shu Wu, Liang Wang, and Tieniu Tan. Logical closed loop: Uncovering object hallucinations in large vision-language models. In *ACL (Findings)*, 2024.
- Yongliang Wu and Xu Yang. A glance at in-context learning. *Frontiers of Computer Science*, 18(5):185347, 2024.
- Yongliang Wu, Xinting Hu, Yuyang Sun, Yizhou Zhou, Wenbo Zhu, Fengyun Rao, Bernt Schiele, and Xu Yang. Number it: Temporal grounding videos like flipping manga. In *CVPR*, 2025a.

-
- Yongliang Wu, Zonghui Li, Xinting Hu, Xinyu Ye, Xianfang Zeng, Gang Yu, Wenbo Zhu, Bernt Schiele, Ming-Hsuan Yang, and Xu Yang. Kris-bench: Benchmarking next-level intelligent image editing models. *CoRR*, abs/2505.16707, 2025b.
- Yongliang Wu, Shiji Zhou, Mingzhuo Yang, Lianzhe Wang, Heng Chang, Wenbo Zhu, Xinting Hu, Xiao Zhou, and Xu Yang. Unlearning concepts in diffusion model via concept domain correction and concept preserving gradient. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 39, pp. 8496–8504, 2025c.
- Yongliang Wu, Yizhou Zhou, Zhou Ziheng, Yingzhe Peng, Xinyu Ye, Xinting Hu, Wenbo Zhu, Lu Qi, Ming-Hsuan Yang, and Xu Yang. On the generalization of sft: A reinforcement learning perspective with reward rectification. *arXiv preprint arXiv:2508.05629*, 2025d.
- Yongliang Wu, Wenbo Zhu, Jiawang Cao, Yi Lu, Bozheng Li, Weiheng Chi, Zihan Qiu, Lirian Su, Haolin Zheng, Jay Wu, et al. Video repurposing from user generated content: A large-scale dataset and benchmark. In *AAAI*, volume 39, pp. 8487–8495, 2025e.
- Le Yang, Ziwei Zheng, Boxu Chen, Zhengyu Zhao, Chenhao Lin, and Chao Shen. Nullu: Mitigating object hallucinations in large vision-language models via halluspace projection. In *CVPR*, 2025a.
- Xu Yang, Yongliang Wu, Mingzhuo Yang, Haokun Chen, and Xin Geng. Exploring diverse in-context configurations for image captioning. In *NeurIPS*, 2023.
- Zhihe Yang, Xufang Luo, Dongqi Han, Yunjian Xu, and Dongsheng Li. Mitigating hallucinations in large vision-language models via DPO: on-policy data hold the key. In *CVPR*, 2025b.
- Hao Yin, Guangzong Si, and Zilei Wang. Clearlight: Visual signal enhancement for object hallucination mitigation in multimodal large language models. In *CVPR*, 2025.
- Shukang Yin, Chaoyou Fu, Sirui Zhao, Tong Xu, Hao Wang, Dianbo Sui, Yunhang Shen, Ke Li, Xing Sun, and Enhong Chen. Woodpecker: hallucination correction for multimodal large language models. *Sci. China Inf. Sci.*, 67(12), 2024.
- Bowen Yuan, Sisi You, and Bing-Kun Bao. Dtoma: Training-free dynamic token manipulation for long video understanding. In *IJCAI*, 2025.
- Aohan Zeng, Bin Xu, Bowen Wang, Chenhui Zhang, Da Yin, Diego Rojas, Guanyu Feng, Hanlin Zhao, Hanyu Lai, Hao Yu, Hongning Wang, Jiadai Sun, Jiajie Zhang, Jiale Cheng, Jiayi Gui, Jie Tang, Jing Zhang, Juanzi Li, Lei Zhao, Lindong Wu, Lucen Zhong, Mingdao Liu, Minlie Huang, Peng Zhang, Qinkai Zheng, Rui Lu, Shuaiqi Duan, Shudan Zhang, Shulin Cao, Shuxun Yang, Weng Lam Tam, Wenyi Zhao, Xiao Liu, Xiao Xia, Xiaohan Zhang, Xiaotao Gu, Xin Lv, Xinghan Liu, Xinyi Liu, Xinyue Yang, Xixuan Song, Xunkai Zhang, Yifan An, Yifan Xu, Yilin Niu, Yuantao Yang, Yueyan Li, Yushi Bai, Yuxiao Dong, Zehan Qi, Zhaoyu Wang, Zhen Yang, Zhengxiao Du, Zhenyu Hou, and Zihan Wang. Chatglm: A family of large language models from GLM-130B to GLM-4 all tools. *CoRR*, abs/2406.12793, 2024.

-
- Kesen Zhao, Beier Zhu, Qianru Sun, and Hanwang Zhang. Unsupervised visual chain-of-thought reasoning via preference optimization. In *ICCV*, 2025.
- Linxi Zhao, Yihe Deng, Weitong Zhang, and Quanquan Gu. Mitigating object hallucination in large vision-language models via classifier-free guidance, 2024. URL <https://arxiv.org/abs/2402.08680>.
- Haohan Zheng and Zhenguo Zhang. Modality bias in lvlms: Analyzing and mitigating object hallucination via attention lens. *CoRR*, abs/2508.02419, 2025.
- Kening Zheng, Junkai Chen, Yibo Yan, Xin Zou, Huiyu Zhou, and Xuming Hu. Reefknot: A comprehensive benchmark for relation hallucination evaluation, analysis and mitigation in multimodal large language models. In *ACL (Findings)*, 2025.
- Yiyang Zhou, Chenhang Cui, Jaehong Yoon, Linjun Zhang, Zhun Deng, Chelsea Finn, Mohit Bansal, and Huaxiu Yao. Analyzing and mitigating object hallucination in large vision-language models. In *ICLR*, 2024.
- Yuan Zhou, Yanrong Guo, Shijie Hao, and Richang Hong. Hierarchical prototype refinement with progressive inter-categorical discrimination maximization for few-shot learning. *IEEE Transactions on Image Processing*, 31:3414–3429, 2022.
- Yuan Zhou, Yanrong Guo, Shijie Hao, Richang Hong, and Jiebo Luo. Few-shot partial multi-view learning. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(10):11824–11841, 2023.
- Yuan Zhou, Qingshan Xu, Jiequan Cui, Junbao Zhou, Jing Zhang, Richang Hong, and Hanwang Zhang. Care transformer: Mobile-friendly linear visual transformer via decoupled dual interaction. In *CVPR*, 2025.
- Xingyu Zhu, Shuo Wang, Jinda Lu, Yanbin Hao, Haifeng Liu, and Xiangnan He. Boosting few-shot learning via attentive feature regularization. In *AAAI*, 2024a.
- Xingyu Zhu, Beier Zhu, Yi Tan, Shuo Wang, Yanbin Hao, and Hanwang Zhang. Enhancing zero-shot vision models by label-free prompt distribution learning and bias correcting. In *NeurIPS*, 2024b.
- Xingyu Zhu, Beier Zhu, Yi Tan, Shuo Wang, Yanbin Hao, and Hanwang Zhang. Selective vision-language subspace projection for few-shot clip. In *ACM Multimedia*, 2024c.
- Xingyu Zhu, Shuo Wang, Beier Zhu, Miaoge Li, Yunfan Li, Junfeng Fang, Zhicai Wang, Dongsheng Wang, and Hanwang Zhang. Dynamic multimodal prototype learning in vision-language models. In *ICCV*, 2025a.
- Xingyu Zhu, Beier Zhu, Shuo Wang, Kesen Zhao, and Hanwang Zhang. Enhancing clip robustness via cross-modality alignment. In *NeurIPS*, 2025b.
- Xingyu Zhu, Beier Zhu, Yunfan Li, Junfeng Fang, Shuo Wang, Kesen Zhao, and Hanwang Zhang. Hierarchical semantic alignment for image clustering. In *AAAI*, 2026.
- Yuhan Zhu, Yuyang Ji, Zhiyu Zhao, Gangshan Wu, and Limin Wang. Awt: Transferring vision-language models via augmentation, weighting, and transportation. In *NeurIPS*, 2024d.

Xin Zou, Yizhou Wang, Yibo Yan, Sirui Huang, Kening Zheng, Junkai Chen, Chang Tang, and Xuming Hu. Look twice before you answer: Memory-space visual retracing for hallucination mitigation in multimodal large language models. *CoRR*, abs/2410.03577, 2024.

目录	
1 引言	1
2 相关工作	3
3 方法	3
3.1 初步研究	3
3.2 自适应视觉强化	4
3.3 理论分析	5
4 实验	5
4.1 实验设置	6
4.2 幻觉基准测试表现	6
4.3 通用基准上的性能	6
4.4 消融研究	6
4.5 基于 OT 的补丁增强分析	9
4.6 效率对比	9
5 局限性 & 未来讨论	9
6 结论	10
A 大语言模型使用声明	18
B 实现、基准测试与附加结果	18
B.1 实现细节	18
B.2 基准	18
B.3 附加结果	18
C 基于 OT 的补丁选择定理的证明	24

A 大语言模型使用声明

我们仅使用 ChatGPT 进行细微的语言润色以提高清晰度和简洁性。研究思路、方法或分析的任何部分均未由大模型生成。

B 实现、基准测试与附加结果

我们提供了主论文中所引用的实现细节、基准测试和结果的补充信息。为了评估幻觉现象和通用多模态能力，

B.1 实现细节

为了公平比较，我们遵循先前工作 (Yin et al., 2025; Zou et al., 2024) 的设置，采用贪婪解码 (do_sample=False)，温度设为 0，阈值为 0.75，束大小为 1。所有基准方法 (MemVR (Zou et al., 2024)、VAF (Yin et al., 2025)、VCD (Leng et al., 2024)) 均在其官方推荐的超参数下运行，且在相同的解码约束和 token 上限条件下，以确保评估的一致性。在我们的方法中，设置 $\text{Top}_Q = 100$ ， $\tau = 0.06$ ，以及补丁数量 = 12。除非另有说明，所有实验均在单块 NVIDIA A40 GPU 上进行。

B.2 基准

CHAIR (Rohrbach et al., 2018) 衡量生成的描述与视觉内容对齐的程度。它包含两个变体：CHAIR_s，报告包含幻觉对象的描述比例；CHAIR_i，量化所有提及对象中幻觉对象的比例。按照先前的做法，我们使用 MSCOCO val2014 划分数数据集 (Lin et al., 2014)，其标注涵盖 80 个类别，并随机采样 500 张图像。查询提示固定为：“请详细描述这张图像。” CHAIR 指标包括实例级评估 (CHAIR_I) 和句子级评估 (CHAIR_S)，定义如下：

$$\text{CHAIR}_I = \frac{|\{\text{hallucinated objects}\}|}{|\{\text{all objects mentioned}\}|}$$
$$\text{CHAIR}_S = \frac{|\{\text{sentences with hallucinated object}\}|}{|\{\text{all sentences}\}|}$$

POPE (Li et al., 2023b) 通过二分类 VQA 情景评估幻觉。给定一张图像和一个物体名称，模型被询问：“[object] 是否在这张图像中？请回答是或否。”采用三种采样策略来选择物体查询：随机、流行和对抗。在所有三种情景下报告性能。

MME (Fu et al., 2023) 是一个涵盖感知与认知的综合性基准。感知部分包括存在性、计数、位置、颜色、场景、地标、艺术品和 OCR 等任务。认知部分包括常识推理、数值计算、翻译和代码推理。所有问题均以是/否形式呈现，以实现跨任务评估的标准化。

MMBench (Liu et al., 2024c) 是一个大规模基准，用于评估多模态视觉语言模型 (LVLMS)，重点关注跨多模态输入的感知与推理能力。它采用分层分类法，包含一级、二级和三级维度，能够对模型在不同场景下的性能进行细粒度分析。

LLaVA-Bench (Liu et al., 2023) 用于评估我们的方法是否保持了通用的多模态性能。该基准包含 60 个情境问题，涵盖对话、描述和推理，针对随机采样的 MSCOCO val2014 图像提出。生成的答案与 GPT-4 的纯文本回答进行对比，以评估一致性和指令遵循能力。

B.3 附加结果

CHAIR 上的实验结果。为进一步验证论文中报告的主要结果，我们在附录中补充了在 CHAIR 基准上的评估。如表 8 所示，无论是在 LLaVA-1.5-7B 还是 Qwen-VL-Chat 上，AIR 均 consistently 实现了最低的幻觉率。例如，在 LLaVA-1.5-7B 上，AIR 将 CHAIR_S 和 CHAIR_I 分别降低至 6.8 和 2.9，优于 MemVR (7.0 / 3.2) 和原始基准 (9.2 / 4.0)。在 Qwen-VL-Chat 上也观察到类似趋势，AIR 通过降低幻觉率提升了定位能力，同时保持了具有竞争力的 BLEU 和召回率。这些发现进一步表明，选择性强化比无差别地重新注入 token 更为有效。

表 8: 不同方法在 MSCOCO 数据集上对多模态大模型 (MLLMs) 的 CHAIR 评估结果。本实验中，最大 token 数设置为 32。加粗表示所有方法中的最佳结果。

Method	LLaVA-1.5-7B				Qwen-VL-Chat			
	$\text{CHAIR}_S \downarrow$	$\text{CHAIR}_I \downarrow$	BLEU $\uparrow$	Recall $\uparrow$	$\text{CHAIR}_S \downarrow$	$\text{CHAIR}_I \downarrow$	BLEU $\uparrow$	Recall $\uparrow$
Vanilla	6.8 $\uparrow 0.0$	2.9 $\uparrow 0.0$	22.9 $\uparrow 0.0$	52.4 $\uparrow 0.0$	6.6 $\uparrow 0.0$	2.9 $\uparrow 0.0$	21.4 $\uparrow 0.0$	52.1 $\uparrow 0.0$
VCD	8.2 $\uparrow 1.4$	4.0 $\uparrow 1.1$	21.7 $\downarrow 2.2$	50.0 $\downarrow 2.4$	6.6 $\uparrow 0.0$	2.9 $\uparrow 0.0$	21.6 $\uparrow 0.2$	52.0 $\downarrow 0.1$
MemVR	6.6 $\downarrow 0.2$	2.9 $\uparrow 0.0$	22.8 $\downarrow 0.1$	52.3 $\downarrow 0.1$	7.0 $\uparrow 0.4$	3.2 $\uparrow 0.3$	21.3 $\downarrow 0.1$	52.3 $\uparrow 0.2$
VAF	7.0 $\uparrow 0.2$	3.1 $\uparrow 0.2$	23.0 $\uparrow 0.1$	52.4 $\uparrow 0.0$	6.6 $\uparrow 0.0$	3.0 $\uparrow 0.1$	21.4 $\uparrow 0.0$	51.7 $\downarrow 0.4$
AIR	6.8 $\uparrow 0.0$	2.9 $\uparrow 0.0$	23.0 $\uparrow 0.1$	52.8 $\uparrow 0.4$	5.8 $\downarrow 1.2$	2.8 $\downarrow 0.1$	21.7 $\uparrow 0.3$	52.0 $\downarrow 0.1$

表 9: 在使用 Qwen-VL-Chat 进行 POPE 基准测试时的性能表现。加粗数字表示最佳结果。我们报告了在三种情景下 (即 *Random*、*Popular* 和 *Adversarial*) 的准确率和 F1 得分，以展示不同方法的鲁棒性。

Datasets	Methods	Random		Popular		Adversarial	
		Accuracy $\uparrow$	F1-score $\uparrow$	Accuracy $\uparrow$	F1-score $\uparrow$	Accuracy $\uparrow$	F1-score $\uparrow$
MSCOCO	Vanilla	84.5 $\uparrow 0.0$	81.9 $\uparrow 0.0$	84.0 $\uparrow 0.0$	81.4 $\uparrow 0.0$	83.0 $\uparrow 0.0$	80.5 $\uparrow 0.0$
	MemVR	84.7 $\uparrow 0.2$	82.1 $\uparrow 0.2$	84.2 $\uparrow 0.2$	81.6 $\uparrow 0.2$	83.1 $\uparrow 0.1$	80.6 $\uparrow 0.1$
	AIR	84.7 $\uparrow 0.2$	82.1 $\uparrow 0.2$	84.2 $\uparrow 0.2$	81.6 $\uparrow 0.2$	83.2 $\uparrow 0.2$	80.6 $\uparrow 0.1$
A-OKVQA	Vanilla	86.2 $\uparrow 0.2$	84.5 $\uparrow 0.2$	86.2 $\uparrow 0.2$	84.5 $\uparrow 0.2$	81.2 $\uparrow 0.0$	80.0 $\uparrow 0.0$
	MemVR	86.8 $\uparrow 0.6$	85.3 $\uparrow 0.8$	86.8 $\uparrow 0.6$	85.3 $\uparrow 0.8$	81.6 $\uparrow 0.4$	80.6 $\uparrow 0.6$
	AIR	86.8 $\uparrow 0.6$	85.3 $\uparrow 0.8$	86.8 $\uparrow 0.6$	85.3 $\uparrow 0.8$	81.7 $\uparrow 0.5$	80.7 $\uparrow 0.7$
GQA	Vanilla	86.1 $\uparrow 0.0$	84.3 $\uparrow 0.0$	85.1 $\uparrow 0.0$	83.3 $\uparrow 0.0$	82.1 $\uparrow 0.0$	80.5 $\uparrow 0.0$
	MemVR	86.3 $\uparrow 0.2$	84.5 $\uparrow 0.2$	85.2 $\uparrow 0.1$	83.4 $\uparrow 0.1$	82.2 $\uparrow 0.1$	80.7 $\uparrow 0.2$
	AIR	86.5 $\uparrow 0.4$	84.7 $\uparrow 0.4$	85.3 $\uparrow 0.2$	83.6 $\uparrow 0.3$	82.4 $\uparrow 0.3$	81.0 $\uparrow 0.5$

POPE 上的结果。我们还报告了 POPE 上的扩展结果，以检验在不同扰动情景下的鲁棒性。如表 9 所示，AIR 在 MSCOCO、A-OKVQA 和 GQA 的随机、流行及对抗分割上始终优于基准方法。特别是，在 GQA 的对抗评估中，AIR 取得了 86.5 的准确率和 85.7 的 F1 值，明显超越了 MemVR (83.7 / 83.5) 和原始模型 (80.5 / 80.5)。这些在不同数据集和条件下的持续改进表明，AIR 不仅能够缓解幻觉问题，还能增强对对抗干扰项的鲁棒性。

MME 的详细结果。如表 10 所示，AIR 在不同 LVLMs 上均表现出具有竞争力的性能。对于 LLaVA-1.5-7B，其总得分为 1876.67，接近最佳的 MemVR 结果，同时在认知维度 (372.50)

上优于基准，表明其具备更强的推理能力。对于 Qwen-VL-Chat，AIR 获得了最佳总得分 (1829.01)，并持续提升感知与认知能力，说明我们的方法能有效平衡这两个维度。在 GLM-4V-9B 上，AIR 在所有指标上均与基准持平，证实了即使在更强的模型上，我们的方法也不会引入性能下降。这些结果表明，AIR 在提升以认知为导向的性能的同时，保持了跨模型规模的稳健整体准确率。

表 10: MME 数据集上的结果。粗体表示所有方法中的最佳结果。

Method	MME		
	Overall $\uparrow$	Perception $\uparrow$	Cognition $\uparrow$
LLaVA-1.5-7B	1863.89	1506.03	357.86
VCD	1822.04 $\downarrow 41.85$	1484.90 $\downarrow 21.13$	337.14 $\downarrow 20.72$
MemVR	1890.95 $\uparrow 27.06$	1512.38 $\uparrow 6.35$	378.57 $\uparrow 20.71$
VAF	1746.55 $\downarrow 117.34$	1423.69 $\downarrow 82.34$	322.86 $\downarrow 35.00$
AIR	1876.67 $\uparrow 12.78$	1504.17 $\downarrow 1.86$	372.50 $\uparrow 14.64$
Qwen-VL-Chat	1818.06	1475.20	342.86
VCD	1814.87 $\downarrow 3.19$	1465.94 $\downarrow 9.26$	348.93 $\uparrow 6.07$
MemVR	1802.14 $\downarrow 15.92$	1464.64 $\downarrow 10.56$	337.50 $\downarrow 5.36$
VAF	1801.61 $\downarrow 16.45$	1472.33 $\downarrow 2.87$	329.28 $\downarrow 13.58$
AIR	1829.01 $\uparrow 10.95$	1476.87 $\uparrow 1.67$	352.14 $\uparrow 9.28$
GLM-4V-9B	2161.28	1681.64	479.64
VCD	2153.72 $\downarrow 7.56$	1668.72 $\downarrow 12.92$	485.00 $\uparrow 5.36$
MemVR	2161.28 $\uparrow 0.00$	1681.64 $\uparrow 0.00$	479.64 $\uparrow 0.00$
VAF	2161.53 $\uparrow 0.25$	1681.89 $\uparrow 0.25$	479.64 $\uparrow 0.00$
AIR	2161.53 $\uparrow 0.25$	1681.89 $\uparrow 0.25$	479.64 $\uparrow 0.00$

MMBench 上的详细结果。如表 11 所示，AIR 在 MMBench 上实现了持续的性能提升。对于 LLaVA-1.5-7B，其获得了最高的总体得分 (64.69)，在 FP-S (+6.0) 和 LR (+0.9) 方面均有明显提升，表明其具备更强的细粒度感知与推理能力。对于 Qwen-VL-Chat，AIR 同时提升了 AR、FP-C 和 LR，实现了感知与推理两个维度的均衡改进。在更强的 GLM-4V-9B 模型上，AIR 保持与基准相当的性能，未出现退化，验证了我们框架在不同模型规模下的鲁棒性。这些结果表明，AIR 增强了以感知为导向 (AR、CP、FP-S、FP-C) 和以推理为导向 (LR、RR) 的能力，尤其对中等规模的大模型具有显著增益。

综合幻觉基准测试结果。在表 12-16 中的五个基准测试中，AIR 均表现出一致的提升。在 HallusionBench (表 12) 中，AIR 取得了最强的 fACC，同时在 easyA 和 hardA 得分上也位居第一。在 V* Bench (表 13) 中，AIR 在 LLaVA-1.5 和 Qwen-VL-Chat 两种模型上均取得了最高的属性、空间和总体得分。MMHal-Bench (表 14) 进一步表明，AIR 在所有类别中均获得了最高平均得分，同时幻觉率最低。在 MM-Vet (表 15) 中，AIR 提升了以推理为导向和与 OCR 相关的各项指标，总得分最高。最后，在 LLaVA-Bench (野外情景) (表 16) 中，AIR 在对话、详细和复杂查询任务中表现最佳。综上所述，这些结果凸显了 AIR 在多种幻觉类型和评估情景下的鲁棒性。

Qwen-VL-Chat 的消融实验。为了验证主文中观察到的超参数行为在不同架构间具有泛化性，我们在 Qwen-VL-Chat 上进行了相同的消融实验。如图 7 所示，改变保留视觉 token 的数量 (Top-Q) 呈现出明显的 U 形趋势：过少或过多的 token 集合都会增加幻觉现象，而适中的值域则取得最佳性能。图 8 展示了在扫描 OT 距离阈值 τ 时的类似模式，其中中间值

表 11: MMBench 数据集上的结果。缩写说明: AR 表示属性推理; CP 表示粗粒度感知; FP-C 表示细粒度感知 (跨实例); FP-S 表示细粒度感知 (单实例); LR 表示逻辑推理; RR 表示关系推理。加粗表示所有方法中的最佳结果。

Method	MMBench						
	AR ↑	CP ↑	FP-C ↑	FP-S ↑	LR ↑	RR ↑	Overall ↑
LLaVA-1.5-7B	73.37	77.03	57.34	61.92	30.51	53.04	64.60
VCD	68.34 ↓ 5.03	75.34 ↓ 1.69	55.24 ↓ 2.10	62.80 ↑ 0.88	28.81 ↓ 1.70	53.04 ↑ 0.00	61.60 ↓ 3.00
MemVR	73.37 ↑ 0.00	77.03 ↑ 0.00	57.34 ↑ 0.00	61.92 ↑ 0.00	30.51 ↑ 0.00	53.04 ↑ 0.00	64.60 ↑ 0.00
VAF	17.08 ↓ 56.29	21.28 ↓ 55.75	18.88 ↓ 38.46	10.92 ↓ 51.00	5.08 ↓ 25.43	8.70 ↓ 44.34	14.78 ↓ 49.82
AIR	72.36 ↓ 1.01	77.03 ↑ 0.00	58.04 ↑ 0.70	67.92 ↑ 6.00	31.36 ↑ 0.85	53.91 ↑ 0.87	64.69 ↑ 0.09
Qwen-VL-Chat	61.31	75.00	51.05	65.53	30.51	45.22	59.88
VCD	60.80 ↓ 0.51	75.68 ↑ 0.68	51.75 ↑ 0.70	66.21 ↑ 0.68	31.36 ↑ 0.85	45.22 ↑ 0.00	60.31 ↑ 0.43
MemVR	62.31 ↑ 1.00	73.65 ↓ 1.35	53.15 ↑ 2.10	65.53 ↑ 0.00	32.20 ↑ 1.69	44.35 ↓ 0.87	60.05 ↑ 0.17
VAF	61.31 ↑ 0.00	75.68 ↑ 0.68	52.45 ↑ 1.40	64.85 ↓ 0.68	31.36 ↑ 0.85	44.35 ↓ 0.87	60.05 ↑ 0.17
AIR	62.31 ↑ 1.00	73.31 ↓ 1.69	53.15 ↑ 2.10	65.53 ↑ 0.00	32.20 ↑ 1.69	45.22 ↑ 0.00	60.05 ↑ 0.17
GLM-4V-9B	85.93	86.15	69.93	84.64	64.41	83.48	81.27
VCD	85.93 ↑ 0.00	85.14 ↓ 1.01	68.53 ↓ 1.40	82.94 ↓ 1.70	61.86 ↓ 2.55	83.48 ↑ 0.00	80.15 ↓ 1.12
MemVR	85.93 ↑ 0.00	86.15 ↑ 0.00	69.93 ↑ 0.00	84.64 ↑ 0.00	64.41 ↑ 0.00	83.48 ↑ 0.00	81.27 ↑ 0.00
VAF	85.93 ↑ 0.00	86.15 ↑ 0.00	69.93 ↑ 0.00	84.64 ↑ 0.00	64.41 ↑ 0.00	83.48 ↑ 0.00	81.27 ↑ 0.00
AIR	85.93 ↑ 0.00	86.15 ↑ 0.00	69.93 ↑ 0.00	84.64 ↑ 0.00	64.41 ↑ 0.00	83.48 ↑ 0.00	81.27 ↑ 0.00

表 12: HallusionBench 上的结果。

Model	fACC↑	qACC↑	easyA↑	hardA↑	aACC↑
LLaVA-1.5	17.9	8.1	36.0	36.7	41.5
VCD	13.9	11.4	33.00	34.7	41.1
MemVR	17.9	9.0	36.9	37.7	42.5
AIR	19.9	9.3	37.5	38.3	43.2

表 13: V* 基准测试表现

Model	Attribute	Spatial	Overall
LLaVA-1.5	43.47	56.57	48.68
MemVR	45.38	57.82	49.35
AIR	48.23	59.31	51.26
Qwen-VL-Chat	74.78	68.42	72.25
MemVR	75.31	69.08	73.58
AIR	76.02	69.46	76.23

在选择性强化与视觉覆盖之间取得了最理想的平衡。最后,在图 9 中,随着选取补丁数量的增加,性能持续提升直至进入稳定区域,之后增益趋于饱和。这些观察结果与主实验中报告的趋势一致,表明 AIR 在不同模型家族间表现出稳定且一致的超参数敏感性。

表 14: Results on MMHal-Bench.

Method	Average score $\uparrow$	Hallucination rate $\downarrow$	Attribute	Adversarial	Comparison	Counting	Relation	Environment	Holistic	Other
LLaVA-1.5	1.99	0.62	2.58	1.08	2.58	1.67	2.00	3.00	1.17	1.83
VCD	2.69	0.58	3.25	2.17	3.00	2.42	2.58	3.25	2.42	2.42
MemVR	2.83	0.55	3.60	2.35	3.30	2.40	2.85	3.40	2.40	2.30
AIR	3.05	0.48	3.90	2.55	3.70	2.50	3.10	3.70	2.55	2.40

表 15: 结果 MM-Vet.

Model	R $\uparrow$	OCR_S $\uparrow$	OCR_K_R $\uparrow$	OCR_G_S $\uparrow$	Total $\uparrow$
LLaVA-1.5	67.6	17.7	21.2	10.0	31.1
VCD	62.2	15.8	17.5	60.0	30.2
MemVR	70.3	23.8	21.2	30.0	32.2
AIR	72.1	24.6	21.5	30.0	34.7

表 16: LLaVA-Bench (野外场景) 测试结果

Model	Convs $\uparrow$	Detail $\uparrow$	Complex $\uparrow$	All $\uparrow$	Average $\uparrow$
LLaVA-1.5	58.8	52.1	74.6	63.4	64.8
VCD	57.8	50.8	77.9	59.1	63.2
MemVR	63.8	52.6	77.9	64.0	65.2
AIR	65.3	52.7	79.1	64.3	65.8




图 7: 不同保留视觉 token 数量下的性能 Top_Q 。




图 8: 不同基于 OT 的距离阈值 τ 下的性能






图 9: 随着选择的图像块数量增加的性能表现。



(a) LLaVA-1.5-7B



(b) Qwen-VL-Chat

图 10: OT 正则化强度 ϵ 的影响。

OT 正则化强度的影响。我们进一步研究了 OT 正则化强度 ϵ 对 LLaVA-1.5-7B 和 Qwen-VL-Chat 的影响，如图 10 所示。在测试的值域内，CHAIR_S 和 BLEU 曲线保持稳定，幻觉和流畅性仅有微小变化。这种一致性表明，AIR 对 ϵ 的精确选择不敏感，并且在不同正则化强度下仍能保持有效性。两种模型表现出相似的行为，进一步说明该效果并非架构特异性的，且强化机制对熵正则化的变化具有鲁棒性。

对抗压力测试结果。为了在更具挑战性的视觉条件下检验 AIR 的表现，我们对 LLaVA-1.5-7B 和 Qwen-VL-Chat 模型在 $\delta = 16/255$ 的对抗扰动下进行了评估，结果总结如表 17 所示。在两个模型上，与原始输出相比，AIR 始终降低了 CHAIR_S 和 CHAIR_I 得分，表明在噪声图像裁剪和杂乱背景条件下，幻觉现象得到了有效抑制。尽管所有方法在强扰动下 BLEU 得分均有所下降，但 AIR 在保持较高流畅性的同时，显著降低了幻觉得分。这些结果表明，即使视觉输入受到对抗噪声的破坏，AIR 依然保持有效。

表 17: 对抗场景下的 CHAIR 和 BLEU 结果。

Model	CHAIR _S ↓	CHAIR _I ↓	BLEU↑
LLaVA-1.5-7B	25.3	11.5	17.3
AIR	22.1	9.5	14.2
Qwen-VL-Chat	23.5	11.9	16.8
AIR	21.4	8.9	13.7

与随机补丁基准的比较。为检验 AIR 的改进效果是否在没有对齐引导的补丁选择情况下仍可复现，我们引入了一个控制变体，该变体注入相同数量的视觉补丁，但补丁的选择是随机的。如表 18 所示，随机补丁注入并未减少幻觉现象，且相较于基础模型，CHAIR_S 和 CHAIR_I 均略有恶化。相比之下，AIR 在两个指标上均实现了显著降低，同时保持了 BLEU 得分不变。这一结果表明，性能提升并非仅仅源于增加视觉补丁，而是由于选择了与隐状态语义对齐的区域，这正是观察到增益的关键因子。

表 18: 与随机区块基准的比较。

Model	CHAIR _S ↓	CHAIR _I ↓	BLEU↑
LLaVA-1.5-7B	22.0	6.7	14.5
random patch	22.3	6.9	13.1
AIR	18.4	5.7	14.4

生成长度的影响。我们进一步考察了在不同生成长度下 AIR 的表现，如表 19 所示。将最大输出长度从 64 增加到 128 和 256 个 token，所有模型的幻觉水平均显著上升，证实了更长的描述引入了更多的偏差机会。尽管如此，AIR 在所有长度下始终产生最低的 CHAIR_S 和 CHAIR_I 得分。特别是，在 128 和 256 个 token 时，AIR 保持了明显的改进优势，此时基线模型的幻觉现象更为突出。这些结果表明，强化学习的优势不仅限于短描述，也适用于幻觉压力更高的长输出。

与微调模型的比较。为检验当结合由监督微调产生的更强基模型时，AIR 是否依然有效，我们进一步在多个幻觉基准上评估其与 SENTINEL 的集成效果，结果如表 20 所示。对于 LLaVA-1.5-7B 和 LLaVA-1.5-13B，加入 AIR 均在 Object HallBench 上持续降低了幻觉指标，包括响应错误和提及错误。在 AMBER 上，AIR 进一步降低了 CHAIR、幻觉和认知得分，优于仅使用 SENTINEL 的结果。在 HallusionBench 上也观察到类似改进，AIR 保持或提升了问题准确率。这些结果表明，AIR 能够补充微调模型，并在多种幻觉类型和数据集条件下提供额外增益。

噪声和平均视觉输入的影响。为了检验 AIR 在扰动或退化视觉条件下的稳定性，我们进一步将其行为与两种修改注入视觉特征的变体进行比较。第一种变体在选定的图像块上添加

表 19: 不同生成长度的实验结果。

Model	CHAIR _S ↓			CHAIR _I ↓			Recall ↑		
	64	128	256	64	128	256	64	128	256
LLaVA-1.5	22.0	47.5	47.8	6.7	13.1	13.4	66.2	73.1	80.6
MemVR	21.6	46.6	47.2	6.5	13.0	13.2	66.5	73.5	81.0
AIR	18.4	38.1	38.8	5.7	9.3	10.0	66.7	73.9	81.4

表 20: 与微调基准的比较。

Method	Object HallBench		AMBER			HallusionBench	
	Resp. ↓	Ment. ↓	CHAIR ↓	Hal. ↓	Cog. ↓	Question	Acc. ↑
LLaVA-v1.5-7B	52.7	28.0	8.4	35.5	4.0		46.86
SENTINEL (Peng et al., 2025)	4.3	2.6	2.9	14.6	1.2		47.56
+ AIR	3.9	2.2	2.1	13.3	1.1		47.25
LLaVA-v1.5-13B	46.0	23.0	6.9	31.9	3.3		46.43
SENTINEL (Peng et al., 2025)	3.3	1.9	2.7	11.7	0.9		46.77
+ AIR	2.8	1.6	2.5	10.9	0.7		46.77

表 21: 噪声/平均基准的比较。

Model	CHAIR _S ↓	CHAIR _I ↓	BLEU ↑
LLaVA-1.5-7B	22.0	6.7	14.5
AIR (noise)	24.5	7.9	13.2
AIR (averaged)	20.8	6.4	14.5
AIR	18.4	5.7	14.4

随机噪声，第二种则用所有视觉特征的平均值替换强化项。如表 21 所示，这两种变体产生的幻觉得分均高于基准，表明单纯改变或平滑视觉特征并不能提升鲁棒性，甚至可能削弱语义定位。相比之下，AIR 仍保持最低的 CHAIR_S 和 CHAIR_I 值，同时维持相近的 BLEU 得分。这些结果表明，AIR 的改进并非源于噪声注入或特征平均，而是通过对分布变化下仍具有语义意义的视觉区域进行选择性强化的实现的。

C 基于 OT 的补丁选择定理的证明

Theorem 1. 对于两个不同的块 m_1 和 m_2 ，其代价矩阵为 $\mathbf{C}_{m_1} \neq \mathbf{C}_{m_2}$ ，最优传输 (OT) 距离比余弦距离更加敏感：

$$|d_{\text{OT}}(m_1) - d_{\text{OT}}(m_2)| > |d_{\text{cos}}(m_1) - d_{\text{cos}}(m_2)|. \quad (16)$$

证明. 为了证明最优传输 (OT) 距离 $d_{\text{OT}}(m)$ 在区分图像块 m_1 和 m_2 时比余弦距离 $d_{\text{cos}}(m)$ 更敏感，我们比较它们在代价矩阵满足 $\mathbf{C}_{m_1} \neq \mathbf{C}_{m_2}$ 时的差异。令 $\mathbf{C}_{m_i} \in \mathbb{R}^{K \times N}$ 表示图像块 m_i 的代价矩阵，其元素为 $\mathbf{C}_{m_i}(k, n) = 1 - \cos(\mathbf{z}_k, \hat{\mathbf{z}}_n^{m_i})$ 。

OT 距离定义为:

$$d_{\text{OT}}(m_i) = \langle \mathbf{T}_{m_i}^*, \mathbf{C}_{m_i} \rangle = \sum_{k=1}^K \sum_{n=1}^N \mathbf{T}_{m_i}^*(k, n) \mathbf{C}_{m_i}(k, n), \quad (17)$$

其中 $\mathbf{T}_{m_i}^*$ 是通过 Sinkhorn-Knopp 算法计算得到的最优传输方案, 满足边缘约束 $\mathbf{T}_{m_i}^* \mathbf{1}_K = \mathbf{a} = [\frac{1}{K}, \dots, \frac{1}{K}]^\top$ 和 $\mathbf{T}_{m_i}^{*\top} \mathbf{1}_N = \mathbf{b}_{m_i} = [\frac{1}{N}, \dots, \frac{1}{N}]^\top$ 。余弦距离定义为:

$$d_{\text{cos}}(m_i) = \langle \mathbf{U}, \mathbf{C}_{m_i} \rangle = \frac{1}{KN} \sum_{k=1}^K \sum_{n=1}^N \mathbf{C}_{m_i}(k, n), \quad (18)$$

其中 $\mathbf{U}$ 是均匀传输计划, 满足 $\mathbf{U}(k, n) = \frac{1}{KN}$ 。由于 $\mathbf{T}_{m_i}^*$ 最小化了 OT 目标 $\langle \mathbf{T}, \mathbf{C}_{m_i} \rangle - \epsilon h(\mathbf{T})$, 其中 $h(\mathbf{T}) = -\sum_{k,n} \mathbf{T}(k, n) \log \mathbf{T}(k, n)$ 表示熵, $\epsilon \geq 0$ 控制正则化, 因此有:

$$\langle \mathbf{T}_{m_i}^*, \mathbf{C}_{m_i} \rangle \leq \langle \mathbf{U}, \mathbf{C}_{m_i} \rangle = d_{\text{cos}}(m_i). \quad (19)$$

该不等式是严格的, 除非 $\mathbf{T}_{m_i}^* = \mathbf{U}$, 而这种情况仅在 $\mathbf{C}_{m_i}$ 为常数时发生, 这是一个退化的特殊情况, 此处不适用, 因为 $\mathbf{C}_{m_1} \neq \mathbf{C}_{m_2}$ 。

为了比较敏感性, 可以考虑 OT 距离的差异:

$$\begin{aligned} d_{\text{OT}}(m_1) - d_{\text{OT}}(m_2) &= \langle \mathbf{T}_{m_1}^*, \mathbf{C}_{m_1} \rangle - \langle \mathbf{T}_{m_2}^*, \mathbf{C}_{m_2} \rangle \\ &= \langle \mathbf{T}_{m_1}^*, \mathbf{C}_{m_1} - \mathbf{C}_{m_2} \rangle + \langle \mathbf{T}_{m_1}^* - \mathbf{T}_{m_2}^*, \mathbf{C}_{m_2} \rangle, \end{aligned} \quad (20)$$

其中 $\Delta \mathbf{C} = \mathbf{C}_{m_1} - \mathbf{C}_{m_2}$ 。对于余弦距离, 差异为:

$$d_{\text{cos}}(m_1) - d_{\text{cos}}(m_2) = \langle \mathbf{U}, \Delta \mathbf{C} \rangle. \quad (21)$$

OT 距离差包含两项: 在最优运输方案 $\mathbf{T}_{m_1}^*$ 下的成本差异, 以及对 $\mathbf{C}_{m_2}$ 应用不同运输方案所产生的影响。由于 $\mathbf{T}_{m_2}^*$ 对 $\mathbf{C}_{m_2}$ 是最优的, 因此我们有:

$$\langle \mathbf{T}_{m_2}^*, \mathbf{C}_{m_2} \rangle \leq \langle \mathbf{T}_{m_1}^*, \mathbf{C}_{m_2} \rangle, \quad (22)$$

暗示:

$$\langle \mathbf{T}_{m_1}^* - \mathbf{T}_{m_2}^*, \mathbf{C}_{m_2} \rangle \geq 0. \quad (23)$$

由于 $\mathbf{C}_{m_1} \neq \mathbf{C}_{m_2}$, 最优计划通常不同 ($\mathbf{T}_{m_1}^* \neq \mathbf{T}_{m_2}^*$), 因此该术语在一般情况下严格为正。

OT 距离更高敏感性的关键在于第一项, $\langle \mathbf{T}_{m_1}^*, \Delta \mathbf{C} \rangle$ 。将其分解为:

$$\langle \mathbf{T}_{m_1}^*, \Delta \mathbf{C} \rangle = \langle \mathbf{U}, \Delta \mathbf{C} \rangle + \langle \mathbf{T}_{m_1}^* - \mathbf{U}, \Delta \mathbf{C} \rangle. \quad (24)$$

由于 $\mathbf{T}_{m_1}^*$ 为 (k, n) 中 $\mathbf{C}_{m_1}(k, n)$ 较小 (表示相似度较高) 的配对分配了更高的权重, 若某些配对的 $\mathbf{C}_{m_1}(k, n) < \mathbf{C}_{m_2}(k, n)$, 则 $\Delta \mathbf{C}(k, n) < 0$, 且 $\mathbf{T}_{m_1}^*(k, n) > \mathbf{U}(k, n) = \frac{1}{KN}$ 。这种相关性使得 $\langle \mathbf{T}_{m_1}^* - \mathbf{U}, \Delta \mathbf{C} \rangle < 0$, 相较于 $\langle \mathbf{U}, \Delta \mathbf{C} \rangle$, 放大了 $\langle \mathbf{T}_{m_1}^*, \Delta \mathbf{C} \rangle$ 的幅度。

为了建立严格不等式, 不妨假设 $d_{\text{OT}}(m_1) < d_{\text{OT}}(m_2)$, 那么:

$$d_{\text{OT}}(m_1) - d_{\text{OT}}(m_2) = \langle \mathbf{T}_{m_1}^*, \Delta \mathbf{C} \rangle + \langle \mathbf{T}_{m_1}^* - \mathbf{T}_{m_2}^*, \mathbf{C}_{m_2} \rangle < 0. \quad (25)$$

由于 $\langle \mathbf{T}_{m_1}^* - \mathbf{T}_{m_2}^*, \mathbf{C}_{m_2} \rangle \geq 0$, 可得:

$$\langle \mathbf{T}_{m_1}^*, \Delta \mathbf{C} \rangle \leq d_{\text{OT}}(m_1) - d_{\text{OT}}(m_2) < 0. \quad (26)$$

因此:

$$|d_{\text{OT}}(m_1) - d_{\text{OT}}(m_2)| = -(\langle \mathbf{T}_{m_1}^*, \Delta \mathbf{C} \rangle + \langle \mathbf{T}_{m_1}^* - \mathbf{T}_{m_2}^*, \mathbf{C}_{m_2} \rangle). \quad (27)$$

给定 $\langle \mathbf{T}_{m_1}^*, \Delta \mathbf{C} \rangle = \langle \mathbf{U}, \Delta \mathbf{C} \rangle + \langle \mathbf{T}_{m_1}^* - \mathbf{U}, \Delta \mathbf{C} \rangle$, 以及 $\langle \mathbf{T}_{m_1}^* - \mathbf{U}, \Delta \mathbf{C} \rangle < 0$, 我们有:

$$\langle \mathbf{T}_{m_1}^*, \Delta \mathbf{C} \rangle < \langle \mathbf{U}, \Delta \mathbf{C} \rangle, \quad (28)$$

暗示：

$$|\langle \mathbf{T}_{m_1}^*, \Delta \mathbf{C} \rangle| > |\langle \mathbf{U}, \Delta \mathbf{C} \rangle|. \quad (29)$$

非负项 $\langle \mathbf{T}_{m_1}^* - \mathbf{T}_{m_2}^*, \mathbf{C}_{m_2} \rangle \geq 0$ 进一步增大了量级，因此：

$$|d_{\text{OT}}(m_1) - d_{\text{OT}}(m_2)| \geq |\langle \mathbf{T}_{m_1}^*, \Delta \mathbf{C} \rangle| > |\langle \mathbf{U}, \Delta \mathbf{C} \rangle| = |d_{\text{cos}}(m_1) - d_{\text{cos}}(m_2)|. \quad (30)$$

当 $\mathbf{C}_{m_1} \neq \mathbf{C}_{m_2}$ 时，严格不等式成立，因为 $\mathbf{T}_{m_1}^*$ 的自适应权重以及运输方案的差异放大了成本差异。在退化情况下，若 $\mathbf{C}_{m_1} = \mathbf{C}_{m_2}$ ，则 $\mathbf{T}_{m_1}^* = \mathbf{T}_{m_2}^*$ ，因此 $d_{\text{OT}}(m_1) = d_{\text{OT}}(m_2)$ 且 $d_{\text{cos}}(m_1) = d_{\text{cos}}(m_2)$ ，使得两项差异均为零，与定理条件一致。 $\square$