

HulluEdit: 用于缓解大型视觉-语言模型幻觉的单次通过证据一致子空间编辑

Yangguang Lin¹, Quan Fang^{1†}, Yufei Li¹, Jiachen Sun¹, Junyu Gao², Jitao Sang³

¹Beijing University of Posts and Telecommunications, Beijing, China

²Institute of Automation, Chinese Academy of Sciences, Beijing, China

³Beijing Jiaotong University, Beijing, China


{sunshinelin, qfang, yufeili, sunjc}@bupt.edu.cn

junyu.gao@nlpr.ia.ac.cn


jtsang@bjtu.edu.cn

Abstract

物体幻觉在大型视觉-语言模型 (LVLMs) 中显著阻碍了其可靠部署。现有方法难以在效率与准确率之间取得平衡：它们通常需要昂贵的参考模型和多次前向传播，或采用静态编辑方式，存在抑制真实视觉证据的风险。为解决这一问题，我们提出 HulluEdit，一种 单次通过、无需参考模型 的干预框架。我们的核心创新是 正交子空间编辑：我们将模型的隐状态分解为正交子空间——视觉证据、冲突先验和残余不确定性——从而实现对幻觉模式的选择性抑制，而不会干扰视觉定位。该方法在数学上保证了对先验子空间施加的编辑不会影响视觉分量。大量实验表明，HulluEdit 在包括 POPE 和 CHAIR 在内的多个基准测试中实现了最先进的幻觉减少效果，同时在 MME 上保持了通用能力，并维持高效的推理性能。我们的方法始终优于对比解码和静态子空间编辑基线，为构建更可信的 LVLM 提供了一条新路径。代码已发布于 <https://github.com/VioAgnes/HulluEdit>。



(a) 传统视觉语言模型存在幻觉问题



(b) HulluEdit (我们的)

图 1. (a) 传统 LVLMs 容易产生物体幻觉，与 (b) 我们提出的 HulluEdit 方法通过正交子空间分解缓解幻觉的对比。

1. 引言

大型视觉语言模型 (LVLMs) [1, 2, 13, 16, 30] 已成为图像描述、视觉问答和辅助交互的标准基础模型。然而，它们仍然容易受到物体幻觉的影响——即在提

供图像时，生成不存在的物体、属性或数量的现象 [15, 17, 20]。如图 1a 所示，这种幻觉通常发生在强大的语言先验覆盖了弱或模糊的视觉证据时，导致生成文本与实际图像内容之间出现不匹配。

† Corresponding author.

为缓解这些幻觉问题，近年来研究人员提出了多种策略。对比解码方法 [5, 12, 14, 18, 24] 通过比较输出分布取得了令人瞩目的效果，但通常需要参考模型或二次推理，增加了延迟和工程复杂性。与此同时，静态子空间编辑技术 [26, 31] 在离线阶段构建数据集级别的幻觉子空间，但缺乏 token 级别的适应性，且存在抑制真实视觉证据的风险。最终，如图 1a 所示，这些方法在抑制语言先验与保留视觉证据之间缺乏可靠的解耦机制和细粒度控制。

受 DeCo [23] 的启发，我们观察到大型模型中层的表示可以作为校准输出层的可靠参考。这促使我们利用中间层构建样本级子空间结构，从而实现对证据-先验竞争更为精细和自适应的控制。通过进一步应用正交分解以分离先验与视觉证据，我们能够有效抑制先验冲突，同时保持稳健的视觉定位。

基于这一洞察，我们提出 HulluEdit，一种单次遍历的子空间编辑框架，该框架将隐状态分解为正交分量：一个在线估计的视觉证据子空间及其正交补空间中的反先验子空间。如图 1b 所示，我们通过加权奇异值分解 (SVD) 构建一个样本自适应的视觉子空间，并从非视觉文本缓存中刻画反先验方向。随后，我们将隐状态投影到这些子空间上并进行逐分量编辑，仅抑制反先验分量而不干扰视觉证据。正交性保证了先验抑制不会损害视觉定位。该方法无需额外训练、无需二次前向传播，且在输出层 Logit 之前编辑隐状态，保持了低开销和易用性。

我们的主要贡献总结如下：

- **正交证据-先验分解**：我们提出一种新颖的子空间构建方法，通过加权奇异值分解估计一个样本自适应的视觉证据子空间，并在其补空间中构建一个正交的反先验子空间，确保视觉保真与先验抑制之间无干扰。
- **证书感知的自适应编辑**：我们引入了一种闭式编辑机制，其自适应强度基于视觉和先验冲突比率，确保证据一致的编辑，同时选择性地抑制幻觉并保持视觉保真度。
- **高效的单次解码推理**：HulluEdit 在解码过程中完全在线运行，无需参考模型、额外前向传播或参数更新。它在多种 LVLM 架构上具有良好的泛化能力，开销极小，在 POPE 和 CHAIR 等基准测试中显著降低了幻觉率，同时保持了 MME 上的图像描述质

量和整体性能。

2. 相关工作

2.1. 视觉幻觉的大型视觉语言模型

大型视觉-语言模型 (LVLMs) 将大型语言模型 [4, 7, 11, 21, 22, 25] 的能力扩展至多模态场景 [1, 2, 6, 13, 16, 19, 30]。在架构上，LVLMs 可大致分为两种范式：基于适配器的系统（例如，BLIP-2、MiniGPT-4、LLaVA、InstructBLIP [6, 13, 16, 30]），通过轻量级适配器将视觉 token 映射到语言空间；以及深度融合设计（例如，Flamingo、Kosmos-2、Qwen-VL [1, 2, 19]），采用交错的视觉-语言注意力机制实现更紧密的模式融合。尽管存在这些架构差异，物体幻觉——即在给定图像的情况下，模型生成关于不存在的物体、属性、数量或关系的流畅描述 [9, 15, 17, 20]——仍是普遍存在于各类 LVLMs 中的根本性挑战。

2.2. 幻觉缓解方法

① 现有缓解视觉幻觉的 LVLM 方法大致可分为三类。训练阶段的方法，如指令微调和视觉偏好对齐 [6, 16]，虽能提升模型可用性，但在推理过程中往往无法完全解决感知证据与语言先验之间的固有矛盾。② 解码阶段的方法，包括对比解码及其变体，旨在通过放大置信输出与不确定输出之间的差异来提高事实性——例如，VCD [12] 强化视觉信号同时抑制干扰性先验，DoLa [5] 调控深层活性值以减少对浅层语义的依赖。然而，这些方法可能无意中削弱了真实的视觉线索。动态零空间解码 [23] 进一步优化该思路，通过逐层视觉信息校准 Logit，但其编辑粒度仍相对粗糙。子空间编辑方法，如 Nullu [26]，通过离线全局投影构建数据集级别的幻觉子空间。然而，这些技术通常为静态，需预先训练子空间，缺乏 token 级自适应能力，且存在抑制合法视觉内容的风险。相比之下，我们的工作提出一种动态、单次传递的子空间编辑框架，实现具有理论保障的在线正交分解，可在不损害视觉基础的前提下实现样本感知干预。

3. 方法

我们提出的 HulluEdit 框架作为一种单次遍历、无需参考的子空间编辑机制，通过分解并选择性地操作隐藏表示，减轻了大型视觉语言模型 (LVLMs) 中的视

$$\text{VCR}(h) = \frac{\|h_U\|_2^2}{\|h\|_2^2 + \epsilon}, \quad \text{PCR}(h) = \frac{\|h_P\|_2^2}{\|h\|_2^2 + \epsilon}$$




图 2. HalluEdit 概述。我们从加权视觉 token 估计一个视觉子空间 U ，从文本缓存中估计一个正交反先验子空间 P ，并保留残差子空间 R 作为不确定性，在编辑时对其进行软正则化 h 。

觉幻觉。如图 2 所示，其核心创新在于构建正交子空间，分别捕捉视觉证据和冲突的语言先验，从而在不损害视觉基础的前提下实现目标干预。

该框架遵循一种严谨的三阶段流水线：首先，我们从锚点 Transformer 层提取视觉特征，并在解码过程中维持一个动态文本缓存。其次，我们通过加权奇异值分解 (SVD) 在线估计一个上下文感知的视觉证据子空间 U ，同时在视觉补全中构建一个正交的反先验子空间 P 。第三，在最终的 Transformer 层，我们将每个隐状态 h 分解为三个正交分量—— h_U 、 h_P 和 h_R ，并应用证据感知的自适应编辑，以保留视觉证据，同时有选择地抑制冲突的先验信息并规范化残差不确定性。

3.1. 正交子空间构造

3.1.1. 层架构与特征抽取

我们建立了一个两层处理架构，以平衡特征的稳定性与编辑的有效性。基于经验观察到物体证据集中于中间层表示 [23]，我们指定一个锚定层 l_a （例如 LLaVA 中的第 26 层）用于稳定特征抽取，以及一个编辑层 l_e 用于干预应用。这种分离确保了鲁棒的视觉特征捕获，同时允许在语言与视觉信息充分融合的点上进行编辑。

每个图像的视觉特征矩阵 $V \in \mathbb{R}^{n_v \times d}$ 仅从锚点层提取一次，并在解码过程中缓存，其中 n_v 表示视觉 token 的数量， d 表示隐状态的维度。同时，我们维护一个动态文本缓存 $T \in \mathbb{R}^{n_t \times d}$ ，通过滑动窗口策略聚合之前解码步骤中的非视觉隐状态，以捕捉可能与视觉证据冲突的演变语言模式。

3.1.2. 上下文感知的视觉证据子空间

视觉相关性在生成步骤中动态变化，因此需要自适应的子空间估计。给定编辑层中的当前隐状态 $h \in \mathbb{R}^d$ ，我们通过规范化的余弦相似度计算 token 级别的相关性权重：

$$w_i = \text{softmax}_i \left(\frac{v_i^\top h}{\|v_i\|_2 \|h\|_2 + \epsilon} \right) \quad (1)$$

原型是 Attention(Q, K, V) = softmax(QK^T / \sqrt{d_k}) V

其中 $\epsilon > 0$ 是一个用于数值稳定性的较小常数。这种权重方案强调了与当前生成上下文语义最对齐的视觉 token。

加权视觉矩阵随后进行截断奇异值分解，以提取主要的视觉成分：

$$U, \Sigma, V^\top = \text{SVD}(W^{1/2}V), \quad U = U_{[:,1:r]} \quad (2)$$

表示当前 token 最相关的视觉语义方向

其中 $W = \text{diag}(w) \in \mathbb{R}^{n_v \times n_v}$ ，且 $\text{SVD}(\cdot)$ 返回完整的奇异值分解。我们仅保留前 r 个左奇异向量 $U \in \mathbb{R}^{d \times r}$ ，它们构成视觉证据子空间的标准正交基 ($U^\top U = I_r$)。该公式遵循加权 PCA 原理，其中 $W^{1/2}$ 确保相关性权重正确融入协方差结构中。

3.1.3. 冲突感知的反先验子空间

为在不损害视觉证据的前提下隔离并抑制冲突的语言模式，我们仅在视觉证据子空间的正交补空间中构建反先验子空间。这一关键设计选择确保了视觉成分与先验成分之间的空间分离：

$$\tilde{T} = T(I_d - UU^\top), \quad P = \text{SVD}_q(\tilde{T}) \quad (3)$$

其中, $\text{SVD}_q(\cdot)$ 计算投影文本缓存 $\tilde{T} \in \mathbb{R}^{n_t \times d}$ 的前- q 个左奇异向量, 得到 $P \in \mathbb{R}^{d \times q}$ 。此处, r 和 q 分别表示视觉证据和反先验子空间的维度。通过构造方式施加正交约束 $U^\top P = 0$, 确保沿 P 施加的抑制对视觉分量 $h_U = UU^\top h$ 完全无影响。

3.1.4. 不确定性感知的残差子空间

我们通过定义残差投影矩阵来完成正交分解:

$$\Pi_R = I_d - \Pi_U - \Pi_P \quad (4)$$

其中 $\Pi_U = UU^\top$ 和 $\Pi_P = PP^\top$ 分别为视觉和反先验投影算子。该残差投影算子 Π_R 捕捉了同时与 U 和 P 正交的分量, 代表无法明确归类为视觉证据或冲突先验的模糊上下文信息。完整的隐状态分解满足:

$$h = \Pi_U h + \Pi_P h + \Pi_R h \quad (5)$$

由于正交性, $\|h\|_2^2 = \|h_U\|_2^2 + \|h_P\|_2^2 + \|h_R\|_2^2$ 项为零。残差分量 h_R 包含通用语言结构、不确定的视觉线索以及需要保守正则化的组合语义, 以防止过度抑制同时保持生成流畅性。

3.2. 自适应子空间编辑

3.2.1. 正交状态分解

对于编辑层中的每个隐状态 $h \in \mathbb{R}^d$, 我们计算其在三个互不相交的子空间上的正交投影:

$$h_U = \Pi_U h = UU^\top h \quad (6)$$

$$h_P = \Pi_P h = PP^\top h \quad (7)$$

$$h_R = \Pi_R h \quad (8)$$

其中 Π_U, Π_P, Π_R 表示满足 $\Pi_U + \Pi_P + \Pi_R = I_d$ 的正交投影算子。正交约束 $\Pi_U \Pi_P = \Pi_U \Pi_R = \Pi_P \Pi_R = 0$ 确保分解具有能量保持性质:

$$h = h_U + h_P + h_R \quad (9)$$

$$\|h\|_2^2 = \|h_U\|_2^2 + \|h_P\|_2^2 + \|h_R\|_2^2 \quad (10)$$

这一数学基础使得每个分量可以独立操作而不会相互干扰, 这是由潜在子空间的正交性所保证的。

3.2.2. 证据感知的强度调度

我们根据视觉证据与冲突先验的相对主导程度, 动态校准编辑强度, 该程度由两个证书度量指标量化:

$$\text{VCR}(h) = \frac{\|h_U\|_2^2}{\|h\|_2^2 + \epsilon}, \quad \text{PCR}(h) = \frac{\|h_P\|_2^2}{\|h\|_2^2 + \epsilon} \quad (11)$$

其中 $\epsilon = 10^{-8}$ 确保了数值稳定性。视觉确定性比 (VCR) 衡量的是视觉证据的显著性, 而先验冲突比 (PCR) 则量化了语言模式之间的冲突强度。

自适应编辑强度采用反比例调度以实现平衡干预:

$$\lambda_n(h) = \min \left(\kappa \cdot \frac{1 - \text{VCR}(h)}{\text{VCR}(h) + \epsilon}, \lambda_{\max} \right) \quad (12)$$

$$\lambda_p(h) = \min \left(\lambda_0 \cdot \frac{\text{PCR}(h)}{1 - \text{PCR}(h) + \epsilon}, \lambda_{\max} \right) \quad (13)$$

其中, $\kappa > 0$ 和 $\lambda_0 > 0$ 是可调节的基础强度, $\lambda_{\max}$ 提供了数值稳定性上限。该公式设计确保了三个关键的行为模式: 当视觉证据较弱 (低 VCR) 时, 会增强非视觉抑制以抵消语言先验; 当存在强烈先验冲突 (高 PCR) 时, 会激活目标性的反先验抑制以减轻幻觉; 在视觉基础稳固的条件下 (高 VCR 且低 PCR), 则自然降低干预强度以保持生成流畅性。

3.2.3. 极小范数闭式编辑

我们将编辑过程表述为一个约束优化问题, 旨在实现最小扰动, 在保持视觉证据的同时达到期望的组件抑制:

$$\min_{\delta \in \mathbb{R}^d} \frac{1}{2} \|\delta\|_2^2 + \frac{\lambda_n}{2} \|\Pi_\perp(h + \delta)\|_2^2 + \frac{\lambda_p}{2} \|\Pi_P(h + \delta)\|_2^2 \quad (14)$$

其中 $\Pi_\perp = I_d - \Pi_U = \Pi_P + \Pi_R$ 将其投影到非视觉补集上。该二次规划的严格凸性保证了存在唯一的闭式解, 我们通过将梯度设为零来推导出该解:

$$\nabla_\delta \mathcal{L} = \delta + \lambda_n \Pi_\perp(h + \delta) + \lambda_p \Pi_P(h + \delta) = 0 \quad (15)$$

求解此线性系统可得到最优编辑状态:

$$h' = h_U + \underbrace{\frac{1}{1 + \lambda_n + \lambda_p}}_{\alpha_P} h_P + \underbrace{\frac{1}{1 + \lambda_n}}_{\alpha_R} h_R \quad (16)$$

此解法精确地保留了视觉分量 h_U ，同时对冲突 (h_P) 和不确定 (h_R) 分量应用强度自适应压缩。压缩因子确保单调抑制：冲突越强，正则化越强烈。

为防止不必要的干预并保持生成质量，我们采用证书感知门控机制：

$$g(h) = \begin{cases} 1 & \text{if } \text{VCR}(h) < \gamma_v \vee \text{PCR}(h) > \gamma_p \\ 0 & \text{otherwise} \end{cases} \quad (17)$$

其中 $\gamma_v, \gamma_p \in [0, 1]$ 为可调阈值，经过校准以平衡幻觉减少与流畅性保持。最终编辑状态变为：

$$h_{\text{final}} = g(h) \cdot h' + (1 - g(h)) \cdot h \quad (18)$$

这种选择性激活机制仅在幻觉风险较高时确保目标干预，最大限度减少对基于充分依据生成内容的干扰。

3.3. 理论保证

我们为 HulluEdit 提供了三项理论保证，这些保证共同确保在有效减少幻觉的同时保留关键属性：**证据一致性**（与视觉证据的对齐度单调提升）、**非干扰性**（正交编辑不会影响视觉组件）以及**稳定性保持**（Lipschitz 连续变换维持生成质量）。详细证明见附录 A。

证据一致性确保我们的编辑过程单调地提升与视觉证据的对齐程度。对于任意隐状态 h 及其编辑后的对应状态 h' ，HulluEdit 保证：

$$\text{VCR}(h') \geq \text{VCR}(h), \quad (19)$$

$$\text{PCR}(h') \leq \text{PCR}(h). \quad (20)$$

证明依赖于闭式解 $h' = h_U + \alpha_P h_P + \alpha_R h_R$ ，其中抑制系数为 $0 < \alpha_P, \alpha_R \leq 1$ ，在保留视觉分量的同时，选择性地抑制先验和残差元素。正交分解确保了 $\|h'\|_2^2 \leq \|h\|_2^2$ ，同时保持 $\|h'_U\|_2^2 = \|h_U\|_2^2$ ，从而提高了视觉置信度比。类似地，先验冲突比的降低源于 $\|h'_P\|_2^2 \leq \|h_P\|_2^2$ 。

这些特性共同确保了 HulluEdit 在减少幻觉的同时，保持视觉证据的完整性和生成的稳定性。

3.4. 计算效率

HulluEdit 通过精心优化的计算设计实现了实际效率。每个 token 的操作主要包含三个阶段。首先，子空

间估计涉及执行加权奇异值分解和瘦奇异值分解，计算成本为 $O(n_v dr + n_t dq)$ 。随后，应用正交投影来分解各分量，需要 $O(d(r + q))$ 次操作。最后，自适应编辑高效地计算融合比例，并在 $O(d)$ 时间内完成闭式更新。这一精简的流水线确保了整个编辑过程的有效性与高效性。

在实际参数 $r = 8$ 、 $q = 5 \ll d = 4096$ 以及有界上下文长度 $n_v \leq 576$ 、 $n_t \leq 512$ 的情况下，总开销减少至 $O(d(r + q))$ ——仅占 Transformer 层 $O(d^2)$ 复杂度的 2% 以下。通过静态视觉缓存和具有常数时间更新的流式文本管理，效率进一步提升。

至关重要的是，HulluEdit 无需额外的前向传播或辅助模型，直接在输出投影之前对隐状态进行修改，同时保持原始模型单次解码的高效性，便于实际部署。

4. 实验

4.1. 实验设置

模型. 为了验证所提出方法的有效性，我们对多个主干网络进行了实验。我们在四种具有代表性的 LVLM 上评估了 HulluEdit：LLaVA-1.5 的 7B 和 13B 两种变体、MiniGPT-4、mPLUG-Owl2 以及 Qwen-VL-Chat-7B。所有模型均采用其官方配置，HulluEdit 仅在推理阶段应用于最终的 Transformer 层，无需重新训练或辅助参考模型。

基准. 我们对比了涵盖三种技术类别的一流幻觉缓解方法。对比解码方法包括 DoLa [5]，其可降低浅层语义影响，以及 VCD [12]，其通过增强视觉证据并减去干扰先验来提升性能。动态修正方法包括 DeCo [23]，用于整合前一层知识，以及 OPERA [10]，用于惩罚过度自信的 token。子空间编辑技术包含 Nullu [26]，采用静态幻觉子空间投影，以及 VAF [27]，用于增强视觉注意力。所有基准方法均在相同提示和解码配置下使用作者推荐的超参数。

解码情景. 我们在 POPE 评估中采用贪婪解码，在图像描述任务中使用核采样，温度设置为保守的 0.05，top-p 为 1.0。所有实验中的最大生成长度均固定为 64 个 token。所有报告的结果均为三次随机种子下的平均值。

实现细节. HulluEdit 使用缓存的视觉状态和累积的非视觉文本状态，在线估计加权奇异值分解子空间。对于 7B 模型，第 26 层作为锚点层，修改作用于最终

表 1. 在 POPE 基准上的对象幻觉评估中, HulluEdit 在所有模型架构和评估划分上均实现了持续改进, 尤其在语言先验最易产生干扰的对抗子集上表现尤为出色。

Category	Method	LLaVA-1.5-7B		LLaVA-1.5-13B		Qwen-VL-Chat-7B	
		Accuracy↑	F1↑	Accuracy↑	F1↑	Accuracy↑	F1↑
Random	Greedy	87.8	87.5	87.6	87.4	88.2	87.9
	VCD	88.4	87.7	88.9	87.8	89.1	88.4
	ICD	88.1	87.6	88.1	87.6	88.9	88.1
	VAE	<u>89.6</u>	<u>89.3</u>	<u>90.1</u>	<u>89.9</u>	<u>90.0</u>	<u>89.7</u>
	DeCo	89.1	<u>89.8</u>	82.2	84.9	87.8	87.2
	Ours	90.4	90.5	90.6	90.8	90.2	89.9
Popular	Greedy	82.5	83.2	82.7	84.1	82.4	83.1
	VCD	83.1	84.1	83.7	85.1	83.0	84.1
	ICD	82.1	82.9	82.9	84.3	83.2	84.5
	VAE	84.5	84.9	<u>85.2</u>	<u>86.4</u>	84.9	<u>85.1</u>
	DeCo	<u>84.6</u>	<u>85.8</u>	78.4	81.7	<u>85.5</u>	84.9
	Ours	87.5	87.6	88.0	88.3	88.2	87.7
Adversarial	Greedy	77.6	79.4	77.8	79.5	77.2	78.9
	VCD	78.1	79.6	78.2	79.7	78.8	80.1
	ICD	78.5	79.9	79.1	80.1	78.1	79.2
	VAE	<u>80.1</u>	81.0	<u>80.7</u>	<u>81.7</u>	80.4	81.2
	DeCo	78.3	<u>81.1</u>	72.6	77.9	<u>81.5</u>	<u>81.5</u>
	Ours	82.5	83.4	82.7	84.0	84.3	84.2

的 Transformer 层。详细的超参数设置, 包括子空间秩、强度参数和证书阈值, 详见附录 B。所有实验均在单个 A100 GPU 上运行, 无需参考模型或额外的前向传播。

4.2. 基准和指标

物体幻觉评估。我们采用两个已建立的基准进行综合评估。POPE 在随机、流行和对抗性划分上采用 VQA 风格的投票来评估物体存在性, 报告准确率和 F1 得分。CHAIR 通过使用 500 张 MSCOCO 图像的实例级和句子级指标来量化图像描述中的物体幻觉, 其指标定义为:

$$\begin{aligned}
 \text{CHAIR}_i &= \frac{|\text{hallucinated objects}|}{|\text{all mentioned objects}|}, \\
 \text{CHAIR}_s &= \frac{|\text{captions with hallucinated objects}|}{|\text{all captions}|}.
 \end{aligned}
 \tag{21}$$

通用能力评估。MME 基准对 14 个不同子任务中的感知和认知能力进行了全面评估, 包括目标识别、属性推理和空间理解。

效率度量。我们通过解码吞吐量 (以每秒处理的 token 数为单位) 来量化实际开销, 测试对象为 500 张




图 3. 以每秒解码的 token 数 (TPS) 为单位的解码吞吐量对比。HulluEdit 实现了具有竞争力的推理速度, 显著快于近期的幻觉缓解方法如 OPERA 和 HALC, 同时保持了出色的性能。

MSCOCO 图像, 不包括预处理。这确保了在相同硬件条件下对不同方法进行公平比较。

4.3. 结果与分析

POPE 评估。HulluEdit 在所有模型架构和评估划分中均表现出一致且显著的幻觉减少效果。如表 1 所示, 我们的方法在全部 18 种评估情景下均取得了最高的准确率和 F1 得分, 尤其在具有挑战性的对抗性 (Adversarial) 划分上表现尤为突出——此时语言先验与视觉证据之间的冲突最为强烈。这些在多种视觉-语

表 2. 在 MSCOCO 数据集上的字幕幻觉评估。我们的方法在 LLaVA-1.5 和 mPLUG-Owl2 上建立了新的最佳性能，证明了正交子空间分解在减少实例级和句子级幻觉方面的有效性。

Method	LLaVA-1.5			MiniGPT-4			mPLUG-Owl2		
	CHAIR _i ↓	CHAIR _s ↓	BLEU ↑	CHAIR _i ↓	CHAIR _s ↓	BLEU ↑	CHAIR _i ↓	CHAIR _s ↓	BLEU ↑
Greedy	7.08	20.40	15.72	12.20	32.40	14.57	8.62	22.90	15.01
Beam Search [8]	6.84	19.50	15.99	11.87	30.10	15.35	7.62	20.30	15.43
DoLa [5]	6.75	20.20	15.68	12.15	31.90	14.54	8.36	22.40	15.13
OPERA [10]	6.07	17.50	16.02	11.96	29.70	14.82	7.18	20.07	15.41
VCD [12]	7.28	20.30	14.53	12.64	29.00	14.42	8.68	22.80	15.14
Woodpecker [28]	7.50	23.85	17.05	10.20	28.87	15.30	8.43	26.33	16.43
LURE [29]	6.50	19.48	15.97	10.20	27.88	15.03	7.67	21.27	15.65
HALC [3]	5.72	16.90	16.02	9.42	25.20	14.91	7.00	18.80	15.33
Nullu [26]	<u>5.30</u>	<u>15.20</u>	15.69	<u>8.99</u>	21.40	14.81	<u>5.77</u>	<u>15.60</u>	15.45
Ours	4.18	13.00	15.49	8.28	<u>23.60</u>	14.76	3.35	13.60	15.34

表 3. MME 细粒度评估。HulluEdit 在牺牲计数性能的前提下提升了目标识别（存在性、位置、颜色）能力，支持视觉与语言先验的分离。

Method	Existence ↑	Count ↑	Position ↑	Color ↑
LLaVA-1.5	181.67	118.33	104.44	152.78
Nullu	190.00	121.11	105.56	156.67
DeCo	175.00	128.33	98.33	125.00
HulluEdit	195.00	105.00	126.67	160.00

言模型 (LVLM) 架构（包括基于适配器、深度融合及混合设计）中持续提升的表现，凸显了我们方法的通用性。至关重要的是，正交约束 $U^T P = 0$ 从数学上保证了对反先验子空间所施加的编辑完全不会影响视觉表示，从而在强先验-证据冲突下仍能维持稳健性能。这种自适应且保留证据的机制使 HulluEdit 区别于静态子空间方法，后者缺乏 token 级别的自适应能力，并存在抑制真实视觉信号的风险。

CHAIR 性能。 HulluEdit 在基于描述的幻觉评估中也表现出卓越性能，有效减少了实例级和句子级的幻觉。如表 2 所总结，我们的方法在 LLaVA-1.5 和 mPLUG-Owl2 上取得了当前最优结果，显著降低了两个指标下的幻觉率。在 MiniGPT-4 上，HulluEdit 依然具有很强的竞争力。句子级幻觉的显著减少进一步表明其能够防止错误传播，即初始的错误对象提及不会引发后续的不准确。这些提升得益于我们提出的正

交分解，该方法能够在不损害视觉定位的前提下，实现对冲突先验和不确定成分的细粒度、token 级抑制。


MME 分析。 HulluEdit 在全面的 MME 基准上表现出与我们设计意图一致的目标性能模式。如表 3 所示，我们的方法在存在性 (+13.33)、位置 (+22.23) 和颜色 (+7.22) 识别方面显著提升，而与 LLaVA-1.5 基准相比，计数性能下降了 (-13.33)。这种选择性提升验证了我们的核心假设：抑制非视觉先验主要有利于对象级识别任务，因为在这些任务中先验知识冲突最为严重。计数性能的权衡表明，细粒度的数值信息可能编码在我们保守正则化的残差子空间中。

效率分析。 HulluEdit 在幻觉缓解与计算效率之间达到了最优平衡，在保持竞争性推理速度的同时实现了显著的性能提升。如图 3 所示，我们的方法在解码吞吐量方面显著优于近期的幻觉缓解方法（包括 OPERA 和 HALC），同时相较于基础解码策略仅引入了适度的开销。这一效率优势源于我们优化的单次遍历设计：正交子空间操作通过低秩近似实现与隐藏维度的线性扩展 ($r = 8, q = 5 \ll d = 4096$)，而基于证书的门控机制仅在高幻觉风险条件下选择性地应用干预措施。实际吞吐量表明，HulluEdit 在真实部署场景中具有可行性，这些场景中准确率和延迟均是关键考量因素。

4.4. 消融研究

我们进行了全面的消融实验，以验证 HulluEdit 中的关键设计选择。结果总结于表 4 中。

层选择与对齐。 关于锚定层选择的实验表明，第 26



Text prompts: Describe this photo in detail.

Llava: The image features a red motorcycle parked on the side of a road, **with a rider sitting on it**. The motorcycle is positioned near a sign, possibly indicating a nearby forest or park. The scene is set in a lush green environment, with trees and bushes surrounding the area. In addition to the motorcycle, there is **a backpack placed on the ground near the rider**, possibly containing personal belongings or supplies for a journey. The overall atmosphere of the scene suggests a leisurely outdoor adventure.

HulluEdit: The image features a motorcycle parked on the side of a road next to a sign signifying White Mountain National Forest. The motorcycle is parked on the grass next to the sign, and there is a signpost signifying National Forest sign. The signpost sign is located near the motorcycle, and the sign signifies national forest sign. In the background, trees and greenery can be seen, creating a scenic view. The roadway is empty, and the motorcycle is the only vehicle visible in the scene.

图 4. 物体幻觉缓解的定性比较。一张示例图像，其标题由 原始模型和我们的 HulluEdit 方法生成。幻觉物体以红色突出显示。

表 4. 在使用 MSCOCO 数据集对 LLaVA-1.5-7B 的 HulluEdit 组件进行消融研究。我们报告实例级 (CHAIR_i) 和句子级 (CHAIR_s) 幻觉率 (越低越好)。 L_a : 锚点层, L_e : 编辑层。

Category	Variant	$\text{CHAIR}_i \downarrow \text{CHAIR}_s \downarrow$	
Full Model	$L_a=26, L_e=\text{last}$	4.18	13.00
Layer Selection	$L_a=20, L_e=\text{last}$	5.55	19.72
	$L_a=30, L_e=\text{last}$	5.37	13.80
Single-layer	$L_a=L_e=\text{last}$	5.50	18.20
Components	uniform SVD	4.85	13.68
	w/o orth. complement	5.60	15.90
	fixed strengths	5.20	13.88
	w/o gating	7.70	22.90
Suppression	residual only	5.90	16.82
	anti-prior only	5.40	14.66

层达到了最佳平衡，相较于更浅或更深的层，其 CHAIR 得分最低。这证实了中间层表示在显著先验抑制之前能够有效捕捉视觉证据。此外，跨层对齐至关重要：使用来自锚定层 26 的特征在顶层进行编辑，显著优于同层估计。这表明中间层的视觉特征能够稳健地抵消深层中的先验抑制，同时保持证据完整性。

核心组件分析。逐组件分析证实了我们方法的核心贡献。加权奇异值分解 (SVD) 始终优于均匀奇异值分解 (SVD)，凸显了上下文感知视觉 token 权重的重要性。正交补构造至关重要，因其缺失会导致性能显著下降，验证了视觉与先验组件间空间分离可防止不期望的干扰。基于视觉-先验比率 (VCR) 和先验-内容比率 (PCR) 的自适应强度调度优于固定强度方案，突显了动态干预校准的价值。证书感知门控能有效避免不

必要的编辑，其移除会导致性能显著下降，强调了其在保持生成流畅性中的作用。

抑制机制的必要性。两种抑制机制对于实现最佳性能都至关重要。单独使用残差或反先验收缩都会导致性能下降，这证实了幻觉源于通用的非视觉成分以及特定的先验冲突。残差组件通过保守的正则化处理模糊的上下文，而反先验子空间则针对冲突的语言模式；两者的协同作用实现了有效的幻觉抑制。

4.5. 案例研究

我们进行了一项定性案例研究，以评估 HulluEdit 在缓解对象幻觉方面的有效性。如图 4 所示，我们将原始 LLaVA 模型与我们的 HulluEdit 框架在一张展示摩托车靠近怀特山国家森林标志的现实世界图像上的生成描述进行了对比。基准模型产生了包含明显幻觉的描述——例如将摩托车错误地放置在道路上，并虚构出地面上有一个“背包”——这些现象是由强烈的语言先验驱动的。相比之下，HulluEdit 正确地将摩托车定位在草地上，准确识别了国家森林标识牌，并避免生成任何虚假对象。这一改进是通过将隐状态分解为正交子空间，并有选择性地抑制冲突的先验模式实现的，从而确保输出严格符合视觉证据。这些结果从定性角度验证了 HulluEdit 增强事实基础的能力。更多示例见附录 C。

5. 结论

我们提出 HulluEdit，一种单次遍历框架，通过将隐状态分解为表示视觉证据、冲突先验和残余不确定性的正交子空间，有效缓解了大型视觉语言模型中的对象幻觉问题。通过在线加权奇异值分解与自适应编

辑, 我们的方法能够选择性抑制幻觉信号, 同时保持视觉定位的准确性。实证评估表明, 该方法在多种架构上均实现了最先进的幻觉减少效果, 同时保持了高质量的图像描述和高效的推理性能。我们的方法为提升大型视觉语言模型的可靠性提供了一种有效替代方案。

6. 致谢

本工作得到了北京市自然科学基金 (JQ24019); 国家自然科学基金 (No. 62576047); SMP-Z 大模型基金 (No. CIPS-SMP20250313); 以及民航协同空管技术与应用重点实验室开放基金 (No. 2025-001) 的资助。

参考文献

- [1] Jean-Baptiste Alayrac, Jeff Donahue, Pauline Luc, Antoine Miech, Iain Barr, Yana Hasson, Karel Lenc, Arthur Mensch, Katherine Millican, Malcolm Reynolds, Roman Ring, Eliza Rutherford, Serkan Cabi, Tengda Han, Zhitao Gong, Sina Samangooei, Marianne Monteiro, Jacob L. Menick, Sebastian Borgeaud, Andy Brock, Aida Nematzadeh, Sahand Sharifzadeh, Mikolaj Binkowski, Ricardo Barreira, Oriol Vinyals, Andrew Zisserman, and Karén Simonyan. Flamingo: a visual language model for few-shot learning. In NeurIPS, 2022.
- [2] Jinze Bai, Shuai Bai, Shusheng Yang, Shijie Wang, Sinan Tan, Peng Wang, Junyang Lin, Chang Zhou, and Jingren Zhou. Qwen-vl: A versatile vision-language model for understanding, localization, text reading, and beyond. 2023.
- [3] Zhaorun Chen, Zhuokai Zhao, Hongyin Luo, Huaxiu Yao, Bo Li, and Jiawei Zhou. HALC: object hallucination reduction via adaptive focal-contrast decoding. In ICML. OpenReview.net, 2024.
- [4] Wei-Lin Chiang, Zhuohan Li, Zi Lin, Ying Sheng, Zhanghao Wu, Hao Zhang, Lianmin Zheng, Siyuan Zhuang, Yonghao Zhuang, Joseph E. Gonzalez, Ion Stoica, and Eric P. Xing. Vicuna: An open-source chatbot impressing gpt-4 with 90%* chatgpt quality, 2023.
- [5] Yung-Sung Chuang, Yujia Xie, Hongyin Luo, Yoon Kim, James R. Glass, and Pengcheng He. Dola: Decoding by contrasting layers improves factuality in large language models. In ICLR. OpenReview.net, 2024.
- [6] Wenliang Dai, Junnan Li, Dongxu Li, Anthony Meng Huat Tiong, Junqi Zhao, Weisheng Wang, Boyang Li, Pascale Fung, and Steven C. H. Hoi. Instructblip: Towards general-purpose vision-language models with instruction tuning. In NeurIPS, 2023.
- [7] DeepSeek-AI. Deepseek-v2: A strong, economical, and efficient mixture-of-experts language model. CoRR, abs/2405.04434, 2024.
- [8] Markus Freitag and Yaser Al-Onaizan. Beam search strategies for neural machine translation. CoRR, abs/1702.01806, 2017.
- [9] Tianrui Guan, Fuxiao Liu, Xiyang Wu, Ruiqi Xian, Zongxia Li, Xiaoyu Liu, Xijun Wang, Lichang Chen, Furong Huang, Yaser Yacoob, Dinesh Manocha, and Tianyi Zhou. Hallusionbench: An advanced diagnostic suite for entangled language hallucination and visual illusion in large vision-language models. In CVPR, pages 14375–14385. IEEE, 2024.
- [10] Qidong Huang, Xiaoyi Dong, Pan Zhang, Bin Wang, Conghui He, Jiaqi Wang, Dahua Lin, Weiming Zhang, and Nenghai Yu. OPERA: alleviating hallucination in multi-modal large language models via over-trust penalty and retrospection-allocation. In CVPR, pages 13418–13427. IEEE, 2024.
- [11] Albert Q. Jiang, Alexandre Sablayrolles, Antoine Roux, Arthur Mensch, Blanche Savary, Chris Bamford, Devendra Singh Chaplot, Diego de Las Casas, Emma Bou Hanna, Florian Bressand, Gianna Lengyel, Guillaume Bour, Guillaume Lample, L  lio Renard Lavaud, Lucile Saulnier, Marie-Anne Lachaux, Pierre Stock, Sandeep Subramanian, Sophia Yang, Szymon Antoniak, Teven Le Scao, Th  ophile Gervet, Thibaut Lavril, Thomas Wang, Timoth  e Lacroix, and William El Sayed. Mixtral of experts. CoRR, abs/2401.04088, 2024.
- [12] Sicong Leng, Hang Zhang, Guanzheng Chen, Xin Li, Shijian Lu, Chunyan Miao, and Lidong Bing. Mitigating object hallucinations in large vision-language models through visual contrastive decoding. In CVPR, pages 13872–13882. IEEE, 2024.
- [13] Junnan Li, Dongxu Li, Silvio Savarese, and Steven C. H. Hoi. BLIP-2: bootstrapping language-image pre-training with frozen image encoders and large language models. In ICML, pages 19730–19742. PMLR, 2023.
- [14] Xiang Lisa Li, Ari Holtzman, Daniel Fried, Percy

- Liang, Jason Eisner, Tatsunori Hashimoto, Luke Zettlemoyer, and Mike Lewis. Contrastive decoding: Open-ended text generation as optimization. In ACL (1), pages 12286–12312. Association for Computational Linguistics, 2023.
- [15] Yifan Li, Yifan Du, Kun Zhou, Jinpeng Wang, Wayne Xin Zhao, and Ji-Rong Wen. Evaluating object hallucination in large vision-language models. In Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, EMNLP 2023, Singapore, December 6-10, 2023, pages 292–305. Association for Computational Linguistics, 2023.
- [16] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. CoRR, abs/2304.08485, 2023.
- [17] Hanchao Liu, Wenyuan Xue, Yifei Chen, Dapeng Chen, Xiutian Zhao, Ke Wang, Liping Hou, Rongjun Li, and Wei Peng. A survey on hallucination in large vision-language models. CoRR, abs/2402.00253, 2024.
- [18] Sean O’Brien and Mike Lewis. Contrastive decoding improves reasoning in large language models. CoRR, abs/2309.09117, 2023.
- [19] Zhiliang Peng, Wenhui Wang, Li Dong, Yaru Hao, Shaohan Huang, Shuming Ma, and Furu Wei. Kosmos-2: Grounding multimodal large language models to the world. CoRR, abs/2306.14824, 2023.
- [20] Anna Rohrbach, Lisa Anne Hendricks, Kaylee Burns, Trevor Darrell, and Kate Saenko. Object hallucination in image captioning. In EMNLP, pages 4035–4045. Association for Computational Linguistics, 2018.
- [21] Llama Team. The llama 3 herd of models. CoRR, abs/2407.21783, 2024.
- [22] Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, Aurélien Rodriguez, Armand Joulin, Edouard Grave, and Guillaume Lample. Llama: Open and efficient foundation language models. CoRR, abs/2302.13971, 2023.
- [23] Chenxi Wang, Xiang Chen, Ningyu Zhang, Bozhong Tian, Haoming Xu, Shumin Deng, and Huajun Chen. MLLM can see? dynamic correction decoding for hallucination mitigation. In ICLR. OpenReview.net, 2025.
- [24] Xintong Wang, Jingheng Pan, Liang Ding, and Chris Biemann. Mitigating hallucinations in large vision-language models with instruction contrastive decoding. In ACL (Findings), pages 15840–15853. Association for Computational Linguistics, 2024.
- [25] An Yang, Baosong Yang, Binyuan Hui, Bo Zheng, Bowen Yu, Chang Zhou, Chengpeng Li, Chengyuan Li, Dayiheng Liu, Fei Huang, Guanting Dong, Haoran Wei, Huan Lin, Jialong Tang, Jialin Wang, Jian Yang, Jianhong Tu, Jianwei Zhang, Jianxin Ma, Jianxin Yang, Jin Xu, Jingren Zhou, Jinze Bai, Jinzheng He, Junyang Lin, Kai Dang, Keming Lu, Keqin Chen, Kexin Yang, Mei Li, Mingfeng Xue, Na Ni, Pei Zhang, Peng Wang, Ru Peng, Rui Men, Ruize Gao, Runji Lin, Shijie Wang, Shuai Bai, Sinan Tan, Tianhang Zhu, Tianhao Li, Tianyu Liu, Wenbin Ge, Xiaodong Deng, Xiaohuan Zhou, Xingzhang Ren, Xinyu Zhang, Xipin Wei, Xuancheng Ren, Xuejing Liu, Yang Fan, Yang Yao, Yichang Zhang, Yu Wan, Yunfei Chu, Yuqiong Liu, Zeyu Cui, Zhenru Zhang, Zhifang Guo, and Zhihao Fan. Qwen2 technical report. CoRR, abs/2407.10671, 2024.
- [26] Le Yang, Ziwei Zheng, Boxu Chen, Zhengyu Zhao, Chenhao Lin, and Chao Shen. Nullu: Mitigating object hallucinations in large vision-language models via halluspace projection. In CVPR, pages 14635–14645. Computer Vision Foundation / IEEE, 2025.
- [27] Hao Yin, Guangzong Si, and Zilei Wang. Clear-sight: Visual signal enhancement for object hallucination mitigation in multimodal large language models. In CVPR, pages 14625–14634. Computer Vision Foundation / IEEE, 2025.
- [28] Shukang Yin, Chaoyou Fu, Sirui Zhao, Tong Xu, Hao Wang, Dianbo Sui, Yunhang Shen, Ke Li, Xing Sun, and Enhong Chen. Woodpecker: Hallucination correction for multimodal large language models. CoRR, abs/2310.16045, 2023.
- [29] Wangbo Zhao, Yizeng Han, Jiasheng Tang, Zhikai Li, Yibing Song, Kai Wang, Zhangyang Wang, and Yang You. A stitch in time saves nine: Small VLM is a precise guidance for accelerating large vlms. In CVPR, pages 19814–19824. Computer Vision Foundation / IEEE, 2025.
- [30] Deyao Zhu, Jun Chen, Xiaoqian Shen, Xiang Li, and Mohamed Elhoseiny. Minigpt-4: Enhancing vision-

language understanding with advanced large language models. In ICLR. OpenReview.net, 2024.

- [31] Xianwei Zhuang, Zhihong Zhu, Yuxin Xie, Liming Liang, and Yuexian Zou. Vaspase: Towards efficient visual hallucination mitigation via visual-aware token sparsification. In CVPR, pages 4189–4199. Computer Vision Foundation / IEEE, 2025.

A. 理论证明

本附录提供了 HulluEdit 理论保证的全面数学证明，包括证据一致性、非干扰性以及稳定性保持。

A.1. 证据一致性证明

命题 1 (证据一致性). 对于任意隐状态 h 及其编辑后的对应状态 h' , HulluEdit 保证证据对齐的单调提升:

$$\text{VCR}(h') \geq \text{VCR}(h), \quad (22)$$

$$\text{PCR}(h') \leq \text{PCR}(h). \quad (23)$$

证明. 证明过程通过分析我们的正交子空间编辑对视觉确定性比率 (VCR) 和先验冲突比率 (PCR) 的影响来进行。

根据公式 (15) 推导出的闭式解，编辑后的状态表示为:

$$h' = h_U + \alpha_P h_P + \alpha_R h_R, \quad (24)$$

其中, $\alpha_P = \frac{1}{1+\lambda_n+\lambda_p}$ 和 $\alpha_R = \frac{1}{1+\lambda_n}$ 分别为先验和残差分量的抑制系数, $\lambda_n, \lambda_p \geq 0$ 表示自适应编辑强度。

根据构造, 式 (9) 中建立的正交子空间分解确保:

$$h = h_U + h_P + h_R, \quad \|h\|_2^2 = \|h_U\|_2^2 + \|h_P\|_2^2 + \|h_R\|_2^2, \quad (25)$$

正交性条件为 $h_U^T h_P = h_U^T h_R = h_P^T h_R = 0$ 。

将此正交性应用于编辑后的状态, 我们得到平方范数的分解:

$$\|h'\|_2^2 = \|h_U\|_2^2 + \alpha_P^2 \|h_P\|_2^2 + \alpha_R^2 \|h_R\|_2^2. \quad (26)$$

由于 $\lambda_n, \lambda_p \geq 0$, 我们得到严格不等式 $0 < \alpha_P, \alpha_R \leq 1$, 这意味着:

$$\|h'\|_2^2 \leq \|h_U\|_2^2 + \|h_P\|_2^2 + \|h_R\|_2^2 = \|h\|_2^2. \quad (27)$$

至关重要的是, 由于正交约束 $U^T P = U^T R = 0$, 视觉成分在我们的编辑过程中完全保持不变:

$$\|h'_U\|_2^2 = \|h_U\|_2^2. \quad (28)$$

我们现在证明视觉确定性比率的第一个不等式。根据定义:

$$\text{VCR}(h') = \frac{\|h'_U\|_2^2}{\|h'\|_2^2} = \frac{\|h_U\|_2^2}{\|h'\|_2^2}. \quad (29)$$

由于 $\|h'\|_2^2 \leq \|h\|_2^2$ 和 $\|h_U\|_2^2 > 0$ (非退化情形下), 我们有:

$$\text{VCR}(h') = \frac{\|h_U\|_2^2}{\|h'\|_2^2} \geq \frac{\|h_U\|_2^2}{\|h\|_2^2} = \text{VCR}(h). \quad (30)$$

当 $\|h'\|_2^2 < \|h\|_2^2$ 时, 不等式是严格的, 这发生在 $\lambda_n + \lambda_p > 0$ 且 h_P 或 h_R 至少有一个非零时。

对于关于先验冲突比的第二个不等式, 我们观察到编辑后的先验分量满足:

$$\|h'_P\|_2^2 = \alpha_P^2 \|h_P\|_2^2 \leq \|h_P\|_2^2, \quad (31)$$

当且仅当 $\lambda_n + \lambda_p = 0$ 或 $h_P = 0$ 时取等号。

现在考虑编辑状态的先验冲突比:

$$\text{PCR}(h') = \frac{\|h'_P\|_2^2}{\|h'\|_2^2} = \frac{\alpha_P^2 \|h_P\|_2^2}{\|h'\|_2^2}. \quad (32)$$

为了建立所需的不等式, 我们分析该比值:

$$\frac{\text{PCR}(h')}{\text{PCR}(h)} = \frac{\alpha_P^2 \|h_P\|_2^2}{\|h'\|_2^2} \cdot \frac{\|h\|_2^2}{\|h_P\|_2^2} = \alpha_P^2 \cdot \frac{\|h\|_2^2}{\|h'\|_2^2}. \quad (33)$$

根据之前的结果, 我们有 $\alpha_P^2 \leq 1$ 和 $\|h\|_2^2 \geq \|h'\|_2^2$, 这意味着:

$$\frac{\text{PCR}(h')}{\text{PCR}(h)} \leq 1 \Rightarrow \text{PCR}(h') \leq \text{PCR}(h). \quad (34)$$

当 $\alpha_P < 1$ 时 (即 $\lambda_n + \lambda_p > 0$) 且 $\|h_P\|_2^2 > 0$ 时, 不等式是严格的。

两个不等式均表明, 我们的编辑过程通过强化视觉定位并抑制冲突的先验信息, 单调地提升了证据一致性, 在非平凡的编辑条件下实现了严格改进。

A.2. 无干扰证明

命题 2 (非干扰性). 正交子空间分解确保对一个子空间施加的编辑不会干扰其他子空间中的组件。

证明. 正交分解构造使得视觉证据子空间 U 、反先验子空间 P 以及残差子空间 R 相互正交:

$$U^T P = 0, \quad U^T R = 0, \quad P^T R = 0. \quad (35)$$

正交投影算子定义为:

$$\Pi_U = U U^T, \quad (36)$$

$$\Pi_P = P P^T, \quad (37)$$

$$\Pi_R = I - \Pi_U - \Pi_P. \quad (38)$$

由于子空间的正交性，我们得到：

$$\Pi_U \Pi_P = UU^T PP^T = 0, \quad (39)$$

由于 $U^T P = 0$ 。类似地：

$$\Pi_U \Pi_R = UU^T (I - UU^T - PP^T) = 0, \quad (40)$$

$$\Pi_P \Pi_R = PP^T (I - UU^T - PP^T) = 0. \quad (41)$$

因此，对任一子空间投影算子所做的修改都不会影响其他分量，从而确保了完全解耦。

A.3. 稳定性保持的证明

命题 3 (稳定性保持) . 编辑变换是收缩的，Lipschitz 常数为 $L \leq 1$ ，确保在序列解码过程中保持稳定。

证明. 编辑变换 $T: \mathbb{R}^d \rightarrow \mathbb{R}^d$ 定义为：

$$T(h) = \Pi_U h + \alpha_P \Pi_P h + \alpha_R \Pi_R h, \quad (42)$$

其中 $\alpha_P = \frac{1}{1+\lambda_n+\lambda_p}$ 和 $\alpha_R = \frac{1}{1+\lambda_n}$ ，满足 $\lambda_n, \lambda_p \geq 0$ 。由于 $0 < \alpha_P, \alpha_R \leq 1$ ，该变换是线性的且收缩的。

对于任意两个隐状态 $h_1, h_2 \in \mathbb{R}^d$ ，我们有：

$$\|T(h_1) - T(h_2)\|_2 \leq \|h_1 - h_2\|_2. \quad (43)$$

因此，Lipschitz 常数 $L \leq 1$ 保证了序列解码过程中的稳定性并保持生成质量。

B. 超参数规范

本附录提供了在 LLaVA-1.5-7B 上进行 HulluEdit 实验的完整超参数配置。所有参数值均通过在保留的开发集上进行系统性实证验证确定，以优化幻觉减少与生成质量之间的权衡。

超参数配置反映了对相互竞争目标的精心权衡。在 $l_a = 26$ 层选择锚点层，以在深层引入显著的语言先验抑制之前捕捉稳健的视觉证据。视觉证据的子空间维度为 $r = 8$ ，反先验组件的子空间维度为 $q = 5$ ，二者在表达能力与计算效率之间取得平衡。强度参数 $\kappa = 0.60$ 和 $\lambda_0 = 0.26$ 控制自适应抑制的强度，根据视觉确定性比率和先验冲突比率指标进行动态调度。所有生成设置均遵循既定的评估协议，以确保在基准测试中与基准方法进行公平比较。

表 5. HulluEdit 在 LLaVA-1.5-7B 上的超参数配置

Parameter	Value
Anchor layer (l_a)	26
Evidence rank (r)	8
Prior rank (q)	5
Base visual (κ)	0.60
Base prior (λ_0)	0.26
Max suppression ($\lambda_{\max}$)	3.6
Stability (ϵ)	1.0×10^{-6}
Generation Settings	
Max tokens	64
Top-p	1.0
Temperature	0.05

C. 定性个案研究

本附录提供了额外的定性案例，展示了 HulluEdit 在缓解对象幻觉的同时保持视觉定位有效性的能力。案例研究说明了我们的方法如何选择性地抑制冲突的语言先验，而不会损害真实的视觉证据。

D. 扩展基准评估

为了对我们的方法进行更全面的评估，我们在两个广泛认可的幻觉基准测试 AMBER 和 Hallu-Bench 上进行了实验。

AMBER 基准. 该基准提供了包括 CHAIR（幻觉率）、覆盖（对象召回率）、幻觉（假正例率）和认知（与推理相关的幻觉）在内的综合指标。如表 6 所示，HulluEdit 实现了最低的 CHAIR 得分 5.3，相比 Vanilla 基准（8.2）将幻觉降低了 35.4%。值得注意的是，我们的方法还将认知幻觉（Cog）显著降低至 2.1，表明推理准确性得到提升。

表 6. AMBER 基准测试结果。↓ 表示越小越好，↑ 表示越大越好。

Method	CHAIR↓	Cover↑	Hal↓	Cog↓
Vanilla	8.2	48.9	34.3	4.0
DeCo	6.6	47.5	28.1	2.8
Ours	5.3	47.0	22.4	2.1



Text prompts: Describe this photo in detail.

Llava: The image features a red motorcycle parked on the side of a road, **with a rider sitting on it**. The motorcycle is positioned near a sign, possibly indicating a nearby forest or park. The scene is set in a lush green environment, with trees and bushes surrounding the area. In addition to the motorcycle, there is **a backpack placed on the ground near the rider**, possibly containing personal belongings or supplies for a journey. The overall atmosphere of the scene suggests a leisurely outdoor adventure.


HulluEdit: The image features a motorcycle parked on the side of a road next to a sign signifying White Mountain National Forest. The motorcycle is parked on the grass next to the sign, and there is a signpost signifying National Forest sign. The signpost sign is located near the motorcycle, and the sign signifies national forest sign. In the background, trees and greenery can be seen, creating a scenic view. The roadway is empty, and the motorcycle is the only vehicle visible in the scene.



Text prompts: Describe this photo in detail.

Llava: The image features a newly married couple, a man and a woman, **standing together under an umbrella**. They are both dressed in formal attire, with the woman wearing a white dress and the man in a suit. The couple is posing for a picture, likely capturing their special day. In the scene, **there are several potted plants**, with one located near the couple and two others further away. **A vase can also be seen**, placed near the couple, adding to the decorative elements of the setting.


HulluEdit: The image features a newly married couple posing for a picture in their wedding attire. The bride is wearing a veil and holds flowers in her hands, while the groom stands beside her. They are both smiling and appear to be enjoying their special day. In the background, there are several cars parked, with one car on the left side of the couple and two cars on the right side. The cars are parked in a line, creating a sense of depth in the scene.



Text prompts: Describe this photo in detail.

Llava: The image features a book titled \"Field Guide to the Birds of Australia,\" which is a book of identification for various bird species found in Australia. The book is open and displayed on a table, showcasing its content. There are several birds depicted in the book, with some of them being colorful and eye-catching. In addition to the book, **there are two potted plants in the scene**, one located on the left side and the other on the right side of the table. **A vase can also be seen on the left side of the table**, adding to the overall decoration of the space.

HulluEdit: The image features a book titled \"Field Guide to Birds of Australia,\" which is a guide to birds of identification. The book is open and covers a significant portion of the image, with birds depicted on its pages. There are several birds visible in the book, with some birds positioned closer to the front cover and others towards the back cover. The birds are of various sizes and colors, showcasing the diversity of bird species found in Australia.



Text prompts: Describe this photo in detail.

Llava: The image features **a mother horse** and her baby horse standing together in a grassy field. **The mother horse** is positioned on the left side of the baby horse, providing protection and guidance. The baby horse is standing close to **the mother**, learning from her and gaining confidence. In the background, there are several houses visible, indicating that the field is located near a residential area. The scene captures the bond between the mother and baby horse, as they enjoy their time together in the open field.

HulluEdit: The image features a horse and its foal grazing in a grass field. The horse is positioned towards the left side of the field, while the foal is standing closer to the center. They are both enjoying the grassy field, with the horse being larger and the foal smaller. In the background, there are a few buildings, possibly farm buildings, and trees, adding to the rural setting. The scene captures the bond between the horse and its foal as they graze together.

图 5. LLaVA-1.5-7B 上物体幻觉缓解的定性对比。基准模型（上方）生成的描述中包含虚假物体（红色突出显示），而 HulluEdit（下方）生成的输出严格符合视觉证据。这些例子展示了我们的方法在抑制矛盾语言先验的同时，保持准确视觉描述的能力。

Hallu-Bench. 该基准评估了幻觉的多个方面：问题准确率（qAcc）、事实准确率（fAcc）和回答准确率（aAcc）。表 7 显示，HulluEdit 在所有指标上均持续优于基线方法，整体得分为 30.1，显著优于 Vanilla (27.6) 和 QLoRA (25.2)。

E. 通用能力保持

幻觉缓解中的一个关键问题是保持模型的通用视觉理解与推理能力。我们采用两个标准基准对 HulluEdit 进行评估：MME（综合感知与认知）和 MMVet

表 7. Hallu-Bench 基准测试结果。

Method	Overall	qAcc	fAcc	aAcc
Vanilla	27.6	13.6	20.5	48.8
QLoRA	25.2	13.2	16.2	46.2
Ours	30.1	16.9	21.4	52.1

(多模态推理)。

如表 8 所示, HulluEdit 在 MMVet 上取得了 28.5 的总得分, 优于 Vanilla 基准 (23.6) 和 DeCo (27.9)。这表明我们的方法不仅减少了幻觉, 还通过消除冲突语言先验的干扰, 提升了整体推理性能。

表 8. MMVet 结果展示了通用能力的保持。

Model	Method	Total
LLaVA-1.5	Vanilla	23.6
LLaVA-1.5	DeCo	27.9
LLaVA-1.5	Ours	28.5

此外, 图 6 展示了 MME 基准测试结果, 表明 HulluEdit 在所有评估维度上均保持或提升了通用视觉理解能力。




图 6. LLaVA-1.5 在 MME 基准上的测试结果表明, HulluEdit 在保持通用视觉理解能力的同时, 有效降低了幻觉现象。

F. 对近期模型的泛化能力

为了验证 HulluEdit 的广泛适用性, 我们在两种最先进的视觉-语言模型: Qwen2.5-VL 和 Intern2.5-VL 上评估了我们的方法。表 9 中的结果表明, 该方法在两个模型上均实现了持续且显著的性能提升。具体而言,

在 Qwen2.5-VL 上, HulluEdit 将 CHAIR_s 从 15.6 降低至 13.2, 将 CHAIR_i 从 6.2 降低至 6.04。在 Intern2.5-VL 上也观察到了类似的效果, 证实了我们方法的强大泛化能力。

表 9. 近期视觉语言模型架构的泛化结果。

Model	Method	CHAIR _s ↓	CHAIR _i ↓	Recall ↑
Qwen2.5-VL	greedy	15.6	6.2	46.0
	Ours	13.2	6.04	45.2
Intern2.5-VL	greedy	15.4	5.4	51.6
	Ours	12.8	5.1	50.9

G. 超参数敏感性分析

我们分析关键超参数的敏感性, 以提供部署方面的实用指导。超参数可分为两类: 与架构相关的参数 (锚定层 l_a 和编辑层 l_e) 以及和学习相关的参数 (r 、 q 和 κ)。

锚点层和编辑层由模型架构决定。具体而言, 锚点层从中间到高层的 Transformer 层中选取, 以确保视觉-语义对齐的稳定性, 而编辑层则始终位于模型的顶层。

如表 10 所示, 其余超参数在实际值域内表现出较低的敏感性。在 $r, q \in [4, 8]$ 和 $\kappa \in [0.3, 0.8]$ 条件下均能稳定获得结果, 所有指标的标准差均小于 0.05。

表 10. LLaVA-1.5-7B 的超参数敏感性分析。

Variable	CHAIR _s ↓	CHAIR _i ↓	Recall ↑
Vanilla	20.4	7.08	54.6
$r = [4, 8]$	13.4 ± 0.4	4.21 ± 0.03	54.5 ± 0.3
$q = [4, 8]$	13.2 ± 0.2	4.20 ± 0.02	54.1 ± 0.2
$\kappa = [0.3, 0.8]$	13.3 ± 0.3	4.22 ± 0.04	54.2 ± 0.2

H. 理论保证的实证验证

为了为我们的理论分析提供更强实证支持, 我们对子空间编辑效果进行了定量分析。对于编辑层中的每个 token, 我们计算了活性值变化 $\Delta h = h_{\text{final}} - h_{\text{orig}}$ 。随后, 我们将 Δh 投影到视觉特征子空间 U 和反

先验子空间 P ，并测量了各自的投影范数 $\|\Delta h_U\|_2$ 和 $\|\Delta h_P\|_2$ 。

实验结果有力地证实了我们的理论假设：视觉子空间内的变化量级远小于反先验子空间内的变化量级 (分别为 10^{-3} 与 10^1 量级)。这为 **视觉证据受到极小干扰**和 **语言先验得到有效抑制**提供了确凿证据，验证了我们方法的核心原则。




图 7. 视觉子空间 (U) 中活性值变化的分布与反先验子空间 (P) 的对比。视觉子空间中的变化幅度相比反先验子空间 (10^1) 小了几个数量级 (10^{-3})，验证了对视觉证据的干扰极小。