

# HulluEdit: 用于缓解大型视觉-语言模型幻觉的单次通过证据一致子空间编辑

Yangguang Lin<sup>1</sup>, Quan Fang<sup>1†</sup>, Yufei Li<sup>1</sup>, Jiachen Sun<sup>1</sup>, Junyu Gao<sup>2</sup>, Jitao Sang<sup>3</sup>

<sup>1</sup>Beijing University of Posts and Telecommunications, Beijing, China

<sup>2</sup>Institute of Automation, Chinese Academy of Sciences, Beijing, China

<sup>3</sup>Beijing Jiaotong University, Beijing, China

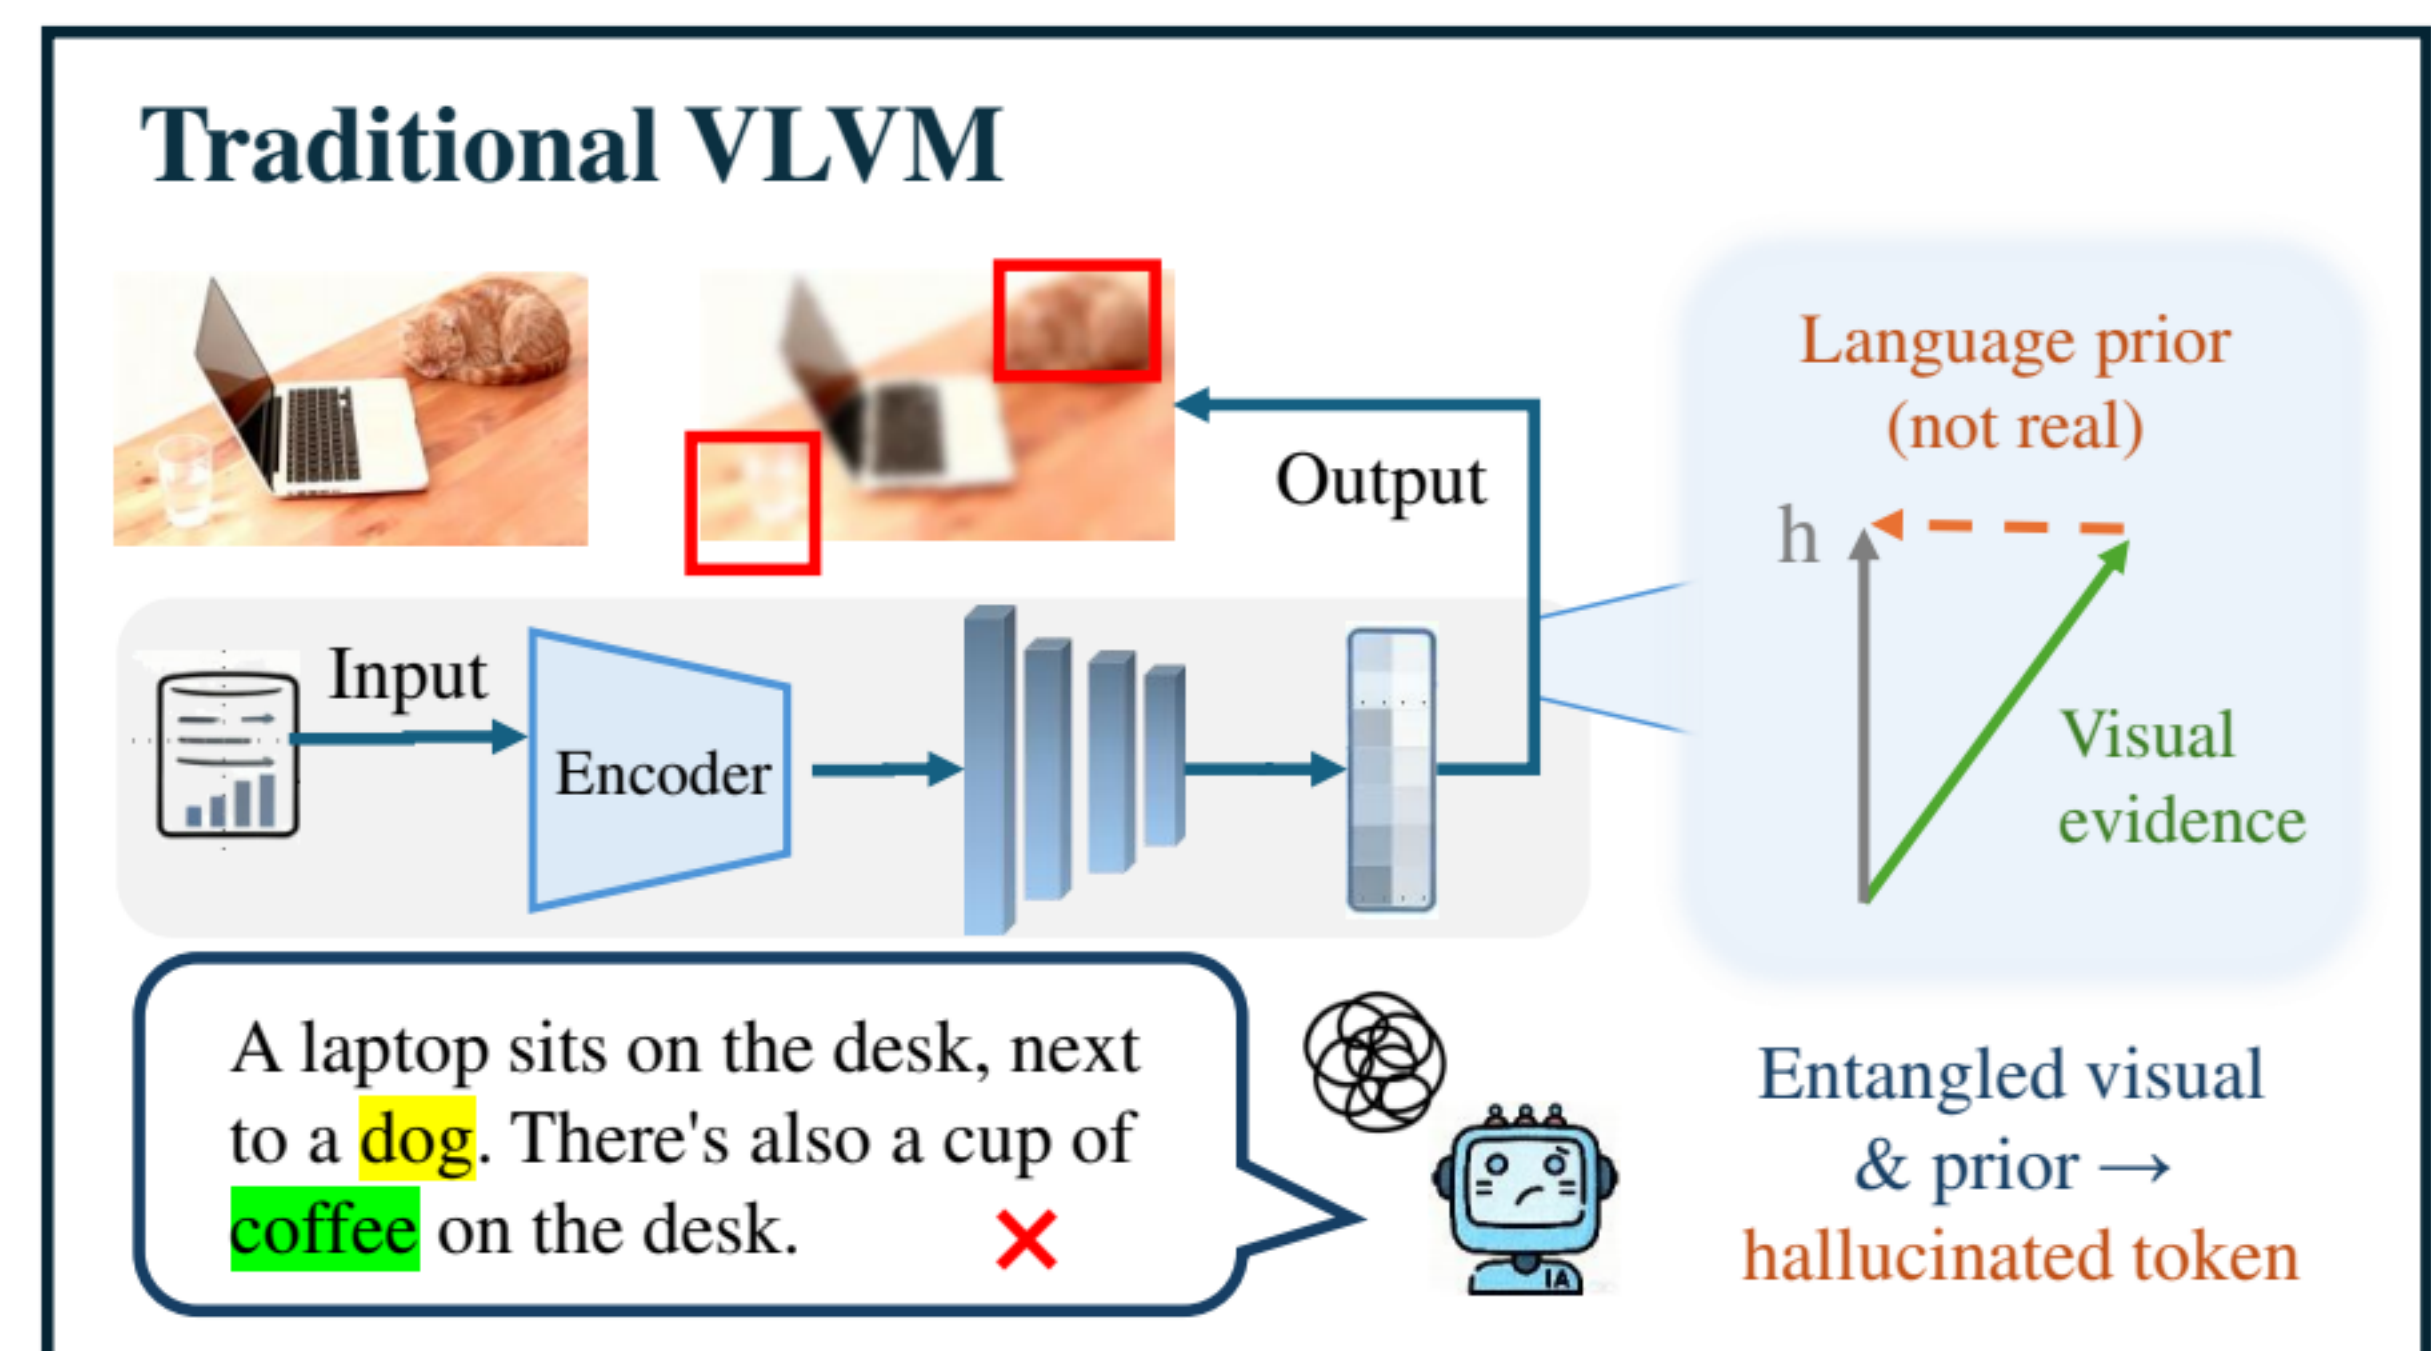
{sunshinelin, qfang, yufeili, sunjc}@bupt.edu.cn

junyu.gao@nlpr.ia.ac.cn


jtsang@bjtu.edu.cn

## Abstract

物体幻觉在大型视觉-语言模型 (LVLMs) 中显著阻碍了其可靠部署。现有方法难以在效率与准确率之间取得平衡：它们通常需要昂贵的参考模型和多次前向传播，或采用静态编辑方式，存在抑制真实视觉证据的风险。为解决这一问题，我们提出 HulluEdit，一种 **单次通过、无需参考模型** 的干预框架。我们的核心创新是 **正交子空间编辑**：我们将模型的隐状态分解为正交子空间——视觉证据、冲突先验和残余不确定性——从而实现对幻觉模式的选择性抑制，而不会干扰视觉定位。该方法在数学上保证了对先验子空间施加的编辑不会影响视觉分量。大量实验表明，HulluEdit 在包括 POPE 和 CHAIR 在内的多个基准测试中实现了最先进的幻觉减少效果，同时在 MME 上保持了通用能力，并维持高效的推理性能。我们的方法始终优于对比解码和静态子空间编辑基线，为构建更可信的 LVLM 提供了一条新路径。代码已发布于 <https://github.com/VioAgnes/HulluEdit>。



(a) 传统视觉语言模型存在幻觉问题



(b) HulluEdit (我们的)

图 1. (a) 传统 LVLMs 容易产生物体幻觉，与 (b) 我们提出的 HulluEdit 方法通过正交子空间分解缓解幻觉的对比。

## 1. 引言

大型视觉语言模型 (LVLMs) [1, 2, 13, 16, 30] 已成为图像描述、视觉问答和辅助交互的标准基础模型。然而，它们仍然容易受到物体幻觉的影响——即在提

供图像时，生成不存在的物体、属性或数量的现象 [15, 17, 20]。如图 1a 所示，这种幻觉通常发生在强大的语言先验覆盖了弱或模糊的视觉证据时，导致生成文本与实际图像内容之间出现不匹配。

<sup>†</sup> Corresponding author.